

<https://github.com/mkdyderski/BSS>

WiFi BSG hasło bsguw123





Rozkłady zmiennych. Testy statystyczne i ich zastosowanie

Hipoteza statystyczna

Dowolne przypuszczenie co do rozkładu populacji generalnej

Prawdziwość tego przypuszczenia jest oceniana na podstawie wyników próby losowej

Hipotezę, która podlega weryfikacji to hipoteza zerowa (H_0) a jej przeciwieństwo to hipoteza alternatywna (H_1)

$H_0 : \mu_1 = \mu_2$ dwie średnie z populacji nie różnią się istotnie

$H_1 : \mu_1 < \mu_2$ dwie średnie z populacji różnią się istotnie

Poziom istotności

Maksymalne ryzyko błędu jakie badacz jest skłonny zaakceptować -
prawdopodobieństwo odrzucenia hipotezy zerowej gdy jest ona prawdziwa

Prawdopodobieństwo P-value

Krytyczny (graniczny) poziom istotności; prawdopodobieństwo testowe

Najmniejszy poziom istotności przy którym dla zaobserwowanej wartości statystyki testowej odrzucilibyśmy hipotezę zerową

Hipotezę zerową odrzucamy, gdy wyliczone prawdopodobieństwo testowe okaże się nie większe od przyjętego przez nas poziomu istotności (**zwykle 0,05**)

Effect size

Obecnie coraz częściej odchodzi się od klasycznych założeń statystycznych w wykrywaniu zależności pomiędzy zmiennymi oraz ich porównywaniu, np.:

- liczba prób nie mniejsza niż 30
- $P < 0.05$
- Wielkość współczynnika korelacji r , czy determinacji R^2

Biol. Rev. (2007), **82**, pp. 591–605.
doi:10.1111/j.1469-185X.2007.00027.x

591

Effect size, confidence interval and statistical significance: a practical guide for biologists

Shinichi Nakagawa^{1,*} and Innes C. Cuthill²

Moving to a World Beyond “ $p < 0.05$ ”

Ronald L. Wasserstein, Allen L. Schirm & Nicole A. Lazar

To cite this article: Ronald L. Wasserstein, Allen L. Schirm & Nicole A. Lazar (2019) Moving to a World Beyond “ $p < 0.05$ ”, *The American Statistician*, 73:sup1, 1-19, DOI: [10.1080/00031305.2019.1583913](https://doi.org/10.1080/00031305.2019.1583913)


To link to this article: <https://doi.org/10.1080/00031305.2019.1583913>

Dlaczego?

Ponieważ często dysponując mniejszymi zbiorami danych (np. w sytuacjach, gdzie pobór prób jest ekstremalnie trudny), już wtedy można zaobserwować jakąś tendencję interpretowalną pod względem ekologicznym

predictor	model parameters			
	estimate	SE	z	Pr(> z)
(intercept)	1.669	0.386	4.314	<0.001
dwarf shrub vegetation cover [%]	2.240	1.175	1.906	0.056

c)




Model zależności liczebności cietrzewia w zależności od pokrycia stanowiska przez zarośla kosówki (Adamowicz i in., w przyg.)

Z drugiej strony, posiadając większy zbiór danych można:

- a) Albo zaobserwować brak istotnych różnic ($P > 0.05$) przy stosunkowo wielkich różnicach pomiędzy średnimi z prób
- b) Albo zaobserwować istotną różnicę ($P > 0.00000001$) przy nikłych różnicach pomiędzy średnimi z prób (w przypadku, gdy liczebność prób jest ogromna)

Dlatego bardziej informatywne jest podanie wielkości różnic oraz ich wyjaśnienie w sensie ekologicznym, gdyż będzie to mniej obciążone artefaktami związanymi z wielkością próby, co może prowadzić do sformułowania nieprawdziwych wniosków




Zmiany różnorodności
taksonomicznej mszaków
epifitycznych BPN po około 20
latach od pierwszych badań
(1992 vs 2016)

Normalność rozkładu

Rozkład zbliżony do normalnego jest jednym z najważniejszych rozkładów w biologii

Rozwiązanie wielu zagadnień statystycznych jest "prostsze", jeśli analizowana cecha ma rozkład normalny

Wiele analiz statystycznych i testów wymaga założenia o normalności rozważanej zmiennej (np. test t-Studenta, analiza wariancji, regresja itd.)



Ocena normalności rozkładu

Histogram


Pytanie: czy średnia sucha masa liści herbaty w przeliczeniu na jeden krzew herbaciany reprezentuje rozkład normalny?

```
ggplot(kofeina.data, aes(x=sucha_masa._mg))+  
  geom_histogram(aes(y=..count..), bins=21, colour="black", fill="#bdbdbd")
```

..count.. – ile jest przypadków w danym przedziale wartości suchej masy

bins – ile ma być przedziałów wartości suchej masy


Tutaj może mało widoczny,
Więc użyjmy jądrowego
estymatora gęstości, by lepiej
pokazać rozkład danych



```
ggplot(kofeina.data, aes(x=sucha_masa._mg))+  
  geom_histogram(aes(y=..density..), bins=21, colour="black", fill="#bdbdbd")+  
  geom_density(alpha=.5, fill="#e31a1c")
```

Jądrowy estymator gęstości
mierzy prawdopodobieństwo,
że losowo wybrana ze zbioru
danych
obserwacja będzie miała
wartość z danego przedziału

..density.. to zmienna
obliczana przez ggplot2,
reprezentująca gęstość
prawdopodobieństwa
zamiast liczby obserwacji
(..count..)



Testy pozwalające na ocenę normalności rozkładu:

- test Kołmogorova-Smirnova

```
fBasics::ksnormTest()
```

- test W Shapiro-Wilka (preferowany ze względu na dużą moc)

```
stats::shapiroTest()
```

Współcześnie mało kto używa tych testów do sprawdzania normalności rozkładu.

Częściej stosuje się metody wizualizacji danych w postaci histogramów.

Ponadto, oceny rozkładu zmiennych można dokonać intuicyjnie, znając strukturę danych

Wskazówka: nie ma idealnie normalnych rozkładów, więc jeśli mamy zmienną ciągłą, nie osiągnącą wartości od 0 do 1, to a priori możemy założyć, że mamy rozkład normalny

Testy statystyczne

Służą do badania istotności różnic pomiędzy próbami

Który użyć kiedy? – zależy od rozkładu

Rozkład normalny

Zakładamy, że zbliżony

Inny (np. Poisson, beta, itd.)

Testy parametryczne

Testy nieparametryczne

Test t Studenta dla par
niewiązanych

Test t Studenta dla par
wiązanych

ANOVA

Test Manna-Whitneya dla par
niewiązanych

Test Manna-Whitneya dla par
wiązanych

Test Kruskala-Wallisa

(„nieparametryczna ANOVA”)

Test Chi-kwadrat

Testy parametryczne

Casus: zmiany w różnorodności porostów epifitycznych w Rezerwacie Ścisłym Białowieskiego Parku Narodowego pomiędzy:

Dwoma terminami badań
time=='h' (1980s)
time=='n' (2010s)

Dwoma typami lasów:
habitat=='conif' (iglasty)
habitat=='decid' (liściasty)

porosty<-read.csv("lichenes1.csv", sep=";",
dec=",")

```
> porosty
```

	plot.id	time	habitat	EIV_N	Rich	Shan
1	A10h	h	decid	3.125000	28	3.245232
2	A10	n	decid	3.158730	40	3.589339
3	A11h	h	decid	2.921569	33	3.404548
4	A11	n	decid	3.253968	42	3.633877
5	A1h	h	decid	2.925000	32	3.394398
6	A1	n	decid	3.225806	43	3.645540
7	A2h	h	decid	3.134615	36	3.486709
8	A2	n	decid	3.350877	40	3.606988
9	A3h	h	decid	3.226415	36	3.499831
10	A3	n	decid	3.094340	41	3.615386
11	A4h	h	decid	3.058824	40	3.606320
12	A4	n	decid	3.116667	44	3.678743
13	A5h	h	decid	3.092593	43	3.663126
14	A5	n	decid	3.166667	35	3.462455
15	A6h	h	decid	3.052632	30	3.317751
16	A6	n	decid	3.075758	46	3.730752
17	A7h	h	decid	2.904762	35	3.466130
18	A7	n	decid	2.785714	37	3.504765
19	A8h	h	decid	2.829787	38	3.551726
20	A8	n	decid	3.121622	48	3.762703
21	A9h	h	decid	2.975610	32	3.376400
22	A9	n	decid	3.048387	42	3.630081
23	B10h	h	decid	3.027027	26	3.174827
24	B10	n	decid	2.942029	46	3.720890

Science of the Total Environment 643 (2018) 468–478



Contents lists available at ScienceDirect

Science of the Total Environment

journal homepage: www.elsevier.com/locate/scitotenv



Changes in the epiphytic lichen biota of Białowieża Primeval Forest are not explained by climate warming

Anna Łubek ^{a,*}, Martin Kukwa ^b, Bogdan Jaroszewicz ^c, Patryk Czortek ^c



Test t Studenta dla par niewiązanych

Stosowany, gdy obserwacje z próby **A** (habitat=='decid') nie odpowiadają obserwacjom z próby **B** (habitat=='conif')

Liczba obserwacji z próby **A** może być równa liczbie obserwacji z próby **B** lub różna od liczby obserwacji z próby **B**

Zakładamy, że Shan reprezentuje rozkład zbliżony do normalnego

```
> summary(porosty$habitat)
conif decid
  100   188
```

```
> porosty
  plot.id time habitat    EIV_N Rich    Shan
1    A10h   h   decid  3.125000   28  3.245232
2     A10   n   decid  3.158730   40  3.589339
3    A11h   h   decid  2.921569   33  3.404548
4     A11   n   decid  3.253968   42  3.633877
5     A1h   h   decid  2.925000   32  3.394398
6      A1   n   decid  3.225806   43  3.645540
7     A2h   h   decid  3.134615   36  3.486709
8      A2   n   decid  3.350877   40  3.606988
9     A3h   h   decid  3.226415   36  3.499831
10     A3   n   decid  3.094340   41  3.615386
11    A4h   h   decid  3.058824   40  3.606320
12     A4   n   decid  3.116667   44  3.678743
```

...

```
159    M5h   h   conif  3.166667   15  2.580638
160     M5   n   conif  3.018182   34  3.450013
161    M6h   h   conif  2.964286   14  2.545620
162     M6   n   conif  3.050000    9  2.128621
163    M7h   h   conif  2.625000   19  2.846864
164     M7   n   conif  2.848485   17  2.729229
165    M8h   h   conif  2.925926   17  2.721485
166     M8   n   conif  2.947368   26  3.142580
```

```
[ reached 'max' / getOption("max.print") -- omitted 122 rows ]
```

H0: Średnia różnorodność gatunkowa (Shan) bioty porostów epifitycznych nie różni się pomiędzy borami a lasami liściastymi

H1: Średnia różnorodność gatunkowa (Shan) bioty porostów epifitycznych różni się istotnie pomiędzy dwoma typami lasów

```
t.test(Shan~habitat, data=porosty, paired=FALSE)
```

Składnia:

- Najpierw to, co porównujemy (Shan)
- Potem to, według czego porównujemy średnie (habitat)
- Oddzielone tyldą ~ (pod esc)
- paired=FALSE może być, nie musi (jak nie ma, to domyślnie test niesparowany)
- data=porosty – skąd ma zassać dane

```
welch Two Sample t-test
```

```
data:  Shan by habitat
t = -10.119, df = 125.27, p-value < 2.2e-16
alternative hypothesis: true difference in means between group conif and group decid is not equal to 0
95 percent confidence interval:
 -0.6487935 -0.4365284
sample estimates:
mean in group conif mean in group decid
      2.966980      3.509641
```

Test t Studenta dla par wiązanych

Stosowany, gdy obserwacje z próby **A** odpowiadają obserwacjom z próby **B**

Liczba obserwacji z próby **A** równa liczbie obserwacji z próby **B**

Dwa poziomy zmiennej time ułożone na przemian (h - historyczne, n – nowe, resampling)

Wiemy, że sparowane po plot.id, np.
A10h – I termin badań (historyczne)
A10 – II termin badań (resampling)

```
> porosty
  plot.id time habitat  EIV_N Rich  Shan
1   A10h   h   decid 3.125000  28 3.245232
2    A10   n   decid 3.158730  40 3.589339
3   A11h   h   decid 2.921569  33 3.404548
4    A11   n   decid 3.253968  42 3.633877
5    A1h   h   decid 2.925000  32 3.394398
6     A1   n   decid 3.225806  43 3.645540
7   A2h   h   decid 3.134615  36 3.486709
8     A2   n   decid 3.350877  40 3.606988
9   A3h   h   decid 3.226415  36 3.499831
10    A3   n   decid 3.094340  41 3.615386
11   A4h   h   decid 3.058824  40 3.606320
12    A4   n   decid 3.116667  44 3.678743
```

...

```
159    M5h   h   conif 3.166667  15 2.580638
160     M5   n   conif 3.018182  34 3.450013
161    M6h   h   conif 2.964286  14 2.545620
162     M6   n   conif 3.050000   9 2.128621
163    M7h   h   conif 2.625000  19 2.846864
164     M7   n   conif 2.848485  17 2.729229
165    M8h   h   conif 2.925926  17 2.721485
166     M8   n   conif 2.947368  26 3.142580
```

```
[ reached 'max' / getoption("max.print") -- omitted 122 rows ]
```

```
> summary(porosty$time)
  h    n 
144 144
```

H0: Średnia różnorodność gatunkowa (Shan) epifitów nie różni się pomiędzy dwoma terminami badań h (1990s) i n (2010s)

H1: Średnia różnorodność gatunkowa (Shan) epifitów różni się pomiędzy dwoma terminami badań h i n

```
t.test(Shan~time, data=porosty, paired=TRUE)
```

```
Paired t-test

data:  Shan by time
t = -14.72, df = 143, p-value < 2.2e-16
alternative hypothesis: true mean difference is not equal to 0
95 percent confidence interval:
 -0.4350827 -0.3320635
sample estimates:
mean difference
 -0.3835731
```

Jednoczynnikowa ANOVA

Casus: różnice w różnorodności porostów epifitycznych (kolumna shan) w Rezerwacie Ścisłym Białowieskiego Parku Narodowego pomiędzy trzema typami lasów:

```
soredy<-read.csv("preden.sor.csv", sep=";", dec=",")  
summary(soredy)
```

forest	ascomata.area	spore.shape	spore.volume	WEIV.L	WEIV.T
Length:144	Min. :0.4188	Min. :2.473	Min. : 94.04	Min. :4.443	Min. :4.323
Class:character	1st Qu.:0.7016	1st Qu.:3.070	1st Qu.: 730.46	1st Qu.:4.897	1st Qu.:4.775
Mode :character	Median :0.9221	Median :3.424	Median : 4950.00	Median :5.079	Median :5.000
	Mean :0.9807	Mean :3.371	Mean : 4821.98	Mean :5.157	Mean :4.945
	3rd Qu.:1.1615	3rd Qu.:3.672	3rd Qu.: 7878.72	3rd Qu.:5.345	3rd Qu.:5.141
	Max. :2.1136	Max. :4.256	Max. :16751.59	Max. :6.107	Max. :5.427
WEIV.K	WEIV.F	WEIV.R	WEIV.N	FRic	FEve
Min. :4.165	Min. :3.901	Min. :2.661	Min. :2.768	Min. : 0.1636	Min. :0.7993
1st Qu.:4.481	1st Qu.:4.157	1st Qu.:3.575	1st Qu.:3.181	1st Qu.: 67.4611	1st Qu.:0.8409
Median :4.668	Median :4.229	Median :3.913	Median :3.321	Median :141.2068	Median :0.8470
Mean :4.758	Mean :4.221	Mean :3.783	Mean :3.311	Mean :159.3163	Mean :0.8472
3rd Qu.:4.964	3rd Qu.:4.279	3rd Qu.:4.129	3rd Qu.:3.444	3rd Qu.:215.9375	3rd Qu.:0.8538
Max. :5.557	Max. :4.537	Max. :4.648	Max. :3.757	Max. :562.6479	Max. :0.8780
FDiv	FDis	rich	shan		
Min. :0.6783	Min. :0.3413	Min. : 37.00	Min. :3.511		
1st Qu.:0.7413	1st Qu.:0.3783	1st Qu.: 70.75	1st Qu.:4.166		
Median :0.7611	Median :0.3893	Median : 85.00	Median :4.343		
Mean :0.7629	Mean :0.3844	Mean : 84.06	Mean :4.307		
3rd Qu.:0.7868	3rd Qu.:0.3929	3rd Qu.: 96.25	3rd Qu.:4.466		
Max. :0.8783	Max. :0.4012	Max. :128.00	Max. :4.754		


```
summary(factor(soredy$forest))
```

```
> summary(factor(soredy$forest))  
   conif mixed_decid      moist  
     50           54         40
```

Hipotezy

H0: $\mu \text{ conif} = \mu \text{ mixed_decid} = \mu \text{ moist}$


H1: Przynajmniej dwie średnie różnią się od siebie istotnie statystycznie



Statystyka testowa F

Bardzo duża wartość F oznacza, że wyjaśniona wariancja (pomiędzy grupami) znacznie przewyższa niewyjaśnioną wariancję (w obrębie grup)

$F = \text{"wyjaśniona wariancja"} / \text{"niewyjaśniona wariancja"}$



Jak zrobić jednoczynnikową ANOVę?

```
summary(aov(shan~forest, data=soredy))
```

```
> summary(aov(shan~forest, data=soredy))
              Df Sum Sq Mean Sq F value    Pr(>F)
forest          2  1.536   0.7679    18.78 5.89e-08 ***
Residuals     141  5.766   0.0409
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Wniosek: średni wskaźnik Shannona epifitów różni się istotnie statystycznie pomiędzy 3 typami lasów

Przyjmujemy H_0 , odrzucamy H_1

Dwuczynnikowa ANOVA

Pato-przykład z dorszem

H0: Ani typ pokarmu, ani jego widzialność nie wpływa na wzrost dorsza

Cladocera



granulki



Cladocera



granulki



Cladocera



granulki



= woda czysta



= woda mętna

Własności zmiennych

Zmienna objaśniana jest ciągła (Growth)

Zmienne objaśniające są kategoryczne
(Food, Visibility)

dorsz1

	Growth	Food	visibility
1	495	mysids	turbid
2	501	mysids	turbid
3	483	mysids	turbid
4	490	mysids	turbid
5	482	mysids	turbid
6	462	mysids	turbid
7	497	mysids	turbid
8	498	mysids	turbid
9	501	mysids	turbid
10	491	mysids	turbid
11	504	mysids	clear
12	528	mysids	clear
13	509	mysids	clear
14	511	mysids	clear
15	525	mysids	clear
16	514	mysids	clear
17	526	mysids	clear
18	518	mysids	clear
19	504	mysids	clear
20	505	mysids	clear
21	527	pellets	turbid
22	526	pellets	turbid
23	519	pellets	turbid
24	525	pellets	turbid

musimy wiedzieć, co chcemy osiągnąć, tzn. jeśli zakładamy addytywność i interakcję między predyktorami, wtedy dajemy znak mnożenia między nimi

```
summary(aov(Growth~Visibility*Food))
```

Jeśli zakładamy tylko addytywność, wtedy dajemy Visibility+Food

Jeśli interesuje nas tylko interakcja, wtedy dajemy Visibility:Food

	Df	Sum Sq	Mean Sq	F value	Pr(>F)	
B1 dorsz1\$Visibility	1	1716	1716	14.10	0.000613	***
B2 dorsz1\$Food	1	6101	6101	50.12	2.58e-08	***
B3 dorsz1\$Visibility:dorsz1\$Food	1	1277	1277	10.49	0.002582	**
Residuals	36	4382	122			

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1						

Interakcja **B3** jest istotna. Na tej podstawie stwierdzamy, że zarówno widzialność pokarmu (**B1**), jak i jego typ (**B2**) istotnie wpływają na wzrost dorsza

Test post-hoc Tukeya

Po zrobieniu ANOVy z dwoma poziomami predyktora (np. dwa punkty w czasie) sytuacja jest prosta

A co, jeśli nasz predyktor ma 3 lub więcej poziomów?

ANOVA dam nam tylko odpowiedź, że są istotne różnice między grupami, ale nie powie nam pomiędzy którymi

Tej odpowiedzi udzieli nam test post-hoc Tukeya (jeden z wielu, ale najczęściej stosowany; inne: LSD Fishera, Duncana)

W R dwie wersje:

pakiet `agricolae` i funkcja `HSD.test`

pakiet `multcomp` i funkcja `glht` (nie działa)

Casus: różnice w różnorodności porostów epifitycznych (kolumna shan) w Rezerwacie Ścisłym Białowieskiego Parku Narodowego pomiędzy trzema typami lasów: conif, mixed_decid, moist
wersja z pakietu agricolae

```
moja.anova<-aov(shan~forest, data=soredy) #zrób ANOVE, a jej wynik trzymaj w obiekcie  
HSD.test(moja.anova, 'forest',console = T) #obiekt z ANOVĄ wrzucić w HSD.test
```

'forest' - w zależności od jakiej kolumny ma być zrobiony Tukey
console = T – musi być, bo inaczej nie wypłuje w konsoli (wada pakietu)

```
Study: moja.anova ~ "forest"

HSD Test for shan

Mean Square Error: 0.040896

forest, means

      shan      std  r      Min      Max
conif    4.165697 0.2632737 50 3.510733 4.695798
mixed_decid 4.372148 0.1765132 54 3.822511 4.746236
moist     4.394804 0.1357487 40 4.076736 4.753943

Alpha: 0.05 ; DF Error: 141
Critical value of Studentized Range: 3.349881

Groups according to probability of means differences and alpha level( 0.05 )

Treatments with the same letter are not significantly different.

      shan groups
moist     4.394804      a
mixed_decid 4.372148      a
conif     4.165697      b
```

Testy nieparametryczne

Jakie inne rozkłady mogą reprezentować dane?

Rozkład Poissona:

rozkład dyskretny, używany do analizy liczebności, np.


liczba osobników

liczba gatunków itd.

liczba morfotypów grzybów związanych z rozkładem biomasy *Solidago canadensis*



```
ggplot(dane, aes(x=rich.morfotypen))+  
  geom_histogram(aes(y=..density..),  
    bins=20, colour="black",  
    fill="#bdbdbd")+  
  geom_density(alpha=.5,  
    fill="#e31a1c")
```




Rozkład log-normalny

`rlnorm()` jest funkcją generującą liczby pseudolosowe z rozkładu log-normalnego o parametrach, które możemy sami określić:

1000, 10, 2 – mówimy R, że ma wylosować 1000 liczb pseudolosowych o średniej 10 i odchyleniu standardowym 2


```
rozklad<-data.frame(x=rlnorm(1000,10,2))  
ggplot(rozklad, aes(x=x))+geom_histogram()
```



Rozkład dwumianowy:


obserwacje przyjmują tylko wartości binarne (jest/nie ma; 1/0)
pozwała odpowiedzieć na pytania:
-czy dany gatunek występuje w danym środowisku, czy nie
-czy przeżywa w danych warunkach, czy nie itd.

np. występowanie *Gentiana pneumonanthe* na łąkach trzęślicowych w zależności od
cech roślinności w otoczeniu




Niche differentiation, competition or habitat filtering?
Mechanisms explaining co-occurrence of plant species on wet
meadows of high conservation value

Rozkład dwumianowy jest bardzo przydatny w szacowaniu prawdopodobieństwa wystąpienia danej obserwacji w zależności od wybranego czynnika, np. występowanie *Triturus vulgaris* w zależności od temperatury



Rozkład beta

Służy do analizy proporcji, np. udziału obcych gatunków roślin (keno_rat) w parkach miejskich w zależności od gęstości sieci rzecznej w otoczeniu



Urban Forestry & Urban Greening 47 (2020) 126525



Contents lists available at [ScienceDirect](#)

Urban Forestry & Urban Greening

journal homepage: www.elsevier.com/locate/ufug



Surrounding landscape influences functional diversity of plant species in urban parks

Patryk Czortek^{a,*}, Remigiusz Pielech^b

^a Białowieża Geobotanical Station, Faculty of Biology, University of Warsaw, ul. Sportowa 19, 17-230 Białowieża, Poland

^b Department of Forest Biodiversity, University of Agriculture in Kraków, al. 29 Listopada 46, 31-425 Kraków, Poland



Test Manna-Whitneya dla par wiązanych

Czy są różnice w bogactwie gatunkowym porostów w Rezerwacie Ścisłym BPN pomiędzy dwoma terminami badań `time=='h'` (1980s) i `time=='n'` (2010s)?

Wracamy do tabelki porosty

Potrzebujemy Rich i time

Sparowanie po plot.id

	plot.id	time	habitat	EIV_N	Rich	Shan
1	A10h	h	decid	3.125000	28	3.245232
2	A10	n	decid	3.158730	40	3.589339
3	A11h	h	decid	2.921569	33	3.404548
4	A11	n	decid	3.253968	42	3.633877
5	A1h	h	decid	2.925000	32	3.394398
6	A1	n	decid	3.225806	43	3.645540
7	A2h	h	decid	3.134615	36	3.486709
8	A2	n	decid	3.350877	40	3.606988

Rich to dane dyskretne,
czyli nie ma rozkładu normalnego

```
wilcox.test(Rich~time, data=porosty, paired=TRUE)
```

```
wilcoxon signed rank test with continuity correction

data:  Rich by time
V = 310.5, p-value < 2.2e-16
alternative hypothesis: true location shift is not equal to 0
```

Test Manna-Whitneya dla par niewiązanych

Czy są różnice w różnorodności funkcjonalnej porostów w Rezerwacie Ścisłym BPN pomiędzy dwoma typami lasu (conif i mixed_decid)?

W tabelce soredy mamy 3 typy lasu. Zróbmy z niej subset i wyłączmy lasy moist:

```
soredy.sub<-subset(soredy, forest != "moist")
```

Potrzebujemy kolumnę FDis (różnorodność funkcjonalna; wartości od 0 do 1) i kolumnę forest

Zakładamy, że FDis to jakaś proporcja,
czyli nie ma rozkładu normalnego

```
wilcox.test(FDis~forest, data= soredy.sub, paired=FALSE)
```

```
wilcoxon rank sum test with continuity correction

data:  FDis by forest
W = 322, p-value = 2.311e-11
alternative hypothesis: true location shift is not equal to 0
```

A co jeśli nasza zmienna grupująca ma więcej niż dwa poziomy?

Test post-hoc Tukeya robimy, gdy zakładamy normalność rozkładu

Dla danych reprezentujących inne rozkłady alternatywa w postaci testu Kruskala-Wallisa

„ANOVA” i test post-hoc w jednym


(pakiet agricolae i funkcja kruskal)

Test post-hoc Kruskala Wallisa

Casus: Czy są różnice w różnorodności funkcjonalnej (FDis) porostów pomiędzy 3 typami lasów?

```
ggplot(soredy, aes(x=forest, y=FDis,  
col=factor(forest)))+geom_boxplot(aes(x=forest, y=FDis, col=factor(forest)))
```

Zakładamy, że
zmienna
objaśniana nie
reprezentuje
rozkładu zbliżonego
do normalnego
(wartości w
zakresie od 0 do 1)



```
library(agricolae)
(kruskal(soredy$FDis, soredy$forest, console=TRUE))
```

Specyficzna składnia – trzeba dolarem \$ przywołać konkretne kolumny
Nawiasy na początku i na końcu () konieczne
console=TRUE też, bo inaczej nie wypłuje w konsoli

```
Post Hoc Analysis

t-Student: 1.976931
Alpha      : 0.05
Groups according to probability of treatment differences and alpha level.

Treatments with the same letter are not significantly different.

      soredy$FDis groups
mixed_decid  93.87037    a
moist        87.57500    a
conif        37.36000    b
$statistics
      chisq Df      p.chisq
54.88081  2 1.210032e-12

$parameters
      test p.adjusted      name.t ntr alpha
kruskal-wallis      none soredy$forest  3 0.05

$means
      soredy.FDis      rank      std      r      Min      Max      Q25      Q50      Q75
conif      0.3722072 37.36000 0.014440783 50 0.3412555 0.3989454 0.3619309 0.3707819 0.3853138
mixed_decid 0.3914424 93.87037 0.005846441 54 0.3732970 0.4011630 0.3881119 0.3919532 0.3953689
moist      0.3902443 87.57500 0.005591479 40 0.3771663 0.4002180 0.3880728 0.3912032 0.3932425


$comparison
NULL

$groups
      soredy$FDis groups
mixed_decid  93.87037    a
moist        87.57500    a
conif        37.36000    b
```

Test Chi kwadrat (tylko dla par niewiązanych)

Do badania różnic
we frekwencji
gatunku np.
pomiędzy dwoma
punktami w czasie,
dwoma siedliskami
itd.

Można tak, ale
można też zrobić
GLM z
binomialem - o
nim w czwartek



```
> freq.epiphytes
  species freq.dec.old freq.dec.new
1  Ram.far         15         72
2  Ino.bys         38         72
3  Ope.niv         84         73
4  Cha.tri         28         74
5  Cha.fur         43         74
6  Prt.coc         52         76
7  Aly.var         72         76
8  Coe.pin          4         77
9  Lcr.arg         72         79
10 Rei.leo          9         81
```



Coenogonium pineti

```
chisq.test(freq.epiphytes[,c(2:3)][8,])
```

```
Chi-squared test for given probabilities

data:  freq.epiphytes[, c(2:3)][8, ]
X-squared = 65.79, df = 1, p-value = 5.016e-16
```

Można zapętląć i pokazać wyniki dla wszystkich gatunków od razu

#pusta tabelka:

```
moje.czi<- data.frame(species = character(),  
                      statistic = numeric(),  
                      p.value = numeric(),  
                      parameter = integer(),  
                      stringsAsFactors = FALSE)
```

#pętla:

```
for (i in 1:nrow(freq.epiphytes)) {  
  obs <- c(freq.epiphytes$freq.dec.old[i], freq.epiphytes$freq.dec.new[i])  
  test <- chisq.test(obs)  
  moje.czi[i, ] <- list(  
    species = freq.epiphytes$species[i],  
    statistic = as.numeric(test$statistic),  
    p.value = test$p.value  
  )  
}  
  
print(results)
```


Tabela z wynikami testu Chi-kwadrat
przeprowadzonego dla 10 gatunków

	species	statistic	p.value
1	Ram.far	37.3448276	9.898305e-10
2	Ino.bys	10.5090909	1.187887e-03
3	Ope.niv	0.7707006	3.800004e-01
4	Cha.tri	20.7450980	5.246571e-06
5	Cha.fur	8.2136752	4.157586e-03
6	Prt.coc	4.5000000	3.389485e-02
7	Aly.var	0.1081081	7.423084e-01
8	Coe.pin	65.7901235	5.015896e-16
9	Lcr.arg	0.3245033	5.689138e-01
10	Rei.leo	57.6000000	3.212256e-14

Jak informację o rozkładach pokazywać w pracach?


W Appendixie – tabela z parametrami testów Shapiro-Wilka/ Kołmogorova-Smirnova (ale komu się chce?)

W Appendixie – obrazki z rozkładami



Albo w tekście manuskryptu jako dodatkowa informacja na obrazkach
wykres strunowy (violin plot) jako dodatek do wykresu pudełkowego (boxplot)
Struna z każdej strony pudełka to jądrowy estymator gęstości - info o rozkładzie

```
ggplot(soredy, aes(x=forest, y=FDis, col=factor(forest)))+  
  scale_colour_manual(values=c("#e34a33", "#238b45", "#2b8cbe"))+  
  geom_violin(aes(x=forest, y=FDis, col=factor(forest)), width=1)+  
  geom_boxplot(aes(x=forest, y=FDis, col=factor(forest)), width=0.1)
```



W praktyce nie jest tak różowo...

Często pracujemy z wieloma zmiennymi jednocześnie, a predyktor jest tylko jeden, np. czas, typ lasu, typ siedliska, itd.

Najpewniej będzie tak, że różne zmienne objaśniane będą reprezentować różne rozkłady...

Co wtedy robić?


Jaki typ rozkładu założyć?

Czy dla każdej zmiennej osobno, tak jak to wynika z rozkładu gęstości prawdopodobieństwa?

A może przyjąć jeden typ rozkładu dla całości?

Casus: różnice w różnorodności funkcjonalnej porostów w Puszczy Białowieskiej w zależności od typu lasu

zarzut recenzenta po popatrzeniu na violin ploty – jaki typ rozkładu dobraliście skoro większość zmiennych objaśnianych mniej lub bardziej odbiega od klasycznego rozkładu normalnego?



Forest Ecology and Management 475 (2020) 118434



ELSEVIER

Contents lists available at [ScienceDirect](https://www.sciencedirect.com)

Forest Ecology and Management

journal homepage: www.elsevier.com/locate/foreco

Identifying mechanisms shaping lichen functional diversity in a primeval forest

Anna Łubek^{a,*}, Martin Kukwa^b, Bogdan Jaroszewicz^c, Patryk Czortek^c

^a The Jan Kochanowski University in Kielce, Institute of Biology, Division of Environmental Biology, Uniwersytecka 7, PL-25-406 Kielce, Poland
^b University of Gdańsk, Faculty of Biology, Department of Plant Taxonomy and Nature Conservation, Wita Stwosza 59, PL-80-308 Gdańsk, Poland
^c University of Warsaw, Faculty of Biology, Białowieża Geobotanical Station, Sportowa 19, PL-17-230 Białowieża, Poland

Odpowiedź na ten zarzut wyglądała następująco:

Założyliśmy wszędzie rozkład normalny - Dlaczego?

Bo gdybyśmy każdą zmienną potraktowali indywidualnie, trudno by było porównywać wyniki między sobą

Byłyby trudności z poprawną diagnozą niektórych dziwnych rozkładów, które reprezentują niektóre zmienne objaśniane

Wniosek – czasem prostota jest lepsza niż wybrzydzenie

Czasem tracimy na jakości, ale zyskujemy generalizację i lepszą „przenośność”/ekstrapolację wyników



Identifying mechanisms shaping lichen functional diversity in a primeval forest

Anna Łubek^{a,*}, Martin Kukwa^b, Bogdan Jaroszewicz^c, Patryk Czortek^c



Casus: cechy funkcjonalne liści herbaty z plantacji w Gruzji (region Batumi)

Wysokość roślin – trochę przypomina rozkład beta, trochę Poisson

%Zawartość kofeiny – trochę log-normal, trochę Poisson, trochę beta

Sucha masa i powierzchnia liści – tu jest w miarę ok, mamy krzywą Gaussa

SLA – chyba log-normal?

Co mamy?

Przy SLA wpływ outliera

Przy zawartości kofeiny

„ciężki ogon”

Co można zrobić?

Usunąć outliera i
założyć, że wszędzie nie
ma rozkładu Gaussa

Usunąć outliera i
transformować dane w taki
sposób, aby był rozkład stał
się bardziej zbliżony do
normalnego

