



BIAŁOWIESKA SZKOŁA STATYSTYKI

Metody ordynacji

Po co komu ordynacje?

Nie są celem w samym w sobie – tło dla bardziej szczegółowych wyników

Grupują obiekty w określonym porządku/kolejności

Zakładają, że istnieje bazowa struktura danych – gradienty środowiskowe porządkujące dane

Różnice w składzie gatunkowym są wyjaśniane przez zmienne charakteryzujące strukturę zespołów gatunkowych lub opisujące parametry środowiskowe



Metody ordynacyjne służą identyfikacji tej podstawowej zależności

Wiele możliwych zmiennych. Które są ważne?


Dają globalny, holistyczny obraz, w przeciwieństwie do regresji, która daje lokalny, indywidualistyczny i redukcjonistyczny pogląd

Co możemy pokazać przy użyciu ordynacji? – kilka przykładów


Zmiany składu gatunkowego w czasie



Diagramy PCA pokazujące różnice w składzie gatunkowym porostów badanych w 1987-89 oraz powtórnie przebadanych w 2014-2015 na poletkach reprezentujących las iglasty (a) oraz las liściasty (b)



Homogenization of species composition of different types of vegetation over time





Based on: Czortek et al. 2018. *Tuexenia*: 38: 177-196.
DOI: 10.14471/2018.38.008


Mechanizmy i kierunki sukcesji roślinności na porzuconych łąkach

Zmiany w kompozycji funkcjonalnej łąk w czasie i w zależności od typu zaburzenia w odniesieniu do dwóch scenariuszy sukcesji:

- z dominacją *Carex acutiformis* (a)
- z dominacją *Salix cinerea* (b)



Niepodobieństwa składu gatunkowego pomiędzy różnymi typami poletek




Ordynacja NMDS pokazująca różnice w składzie gatunkowym porostów epifitycznych pomiędzy poletkami reprezentującymi las iglasty (coniferous), liściasty (mixed deciduous) i wilgotny (floodplain and swamp)


Łubek et al. 2020. Forest Ecol Manage 475: 118434
<https://doi.org/10.1016/j.foreco.2020.118434>

Modelowanie nisz realizowanych gatunków rzadkich

Ordynacja DCA przeprowadzona dla poletek z oraz bez obecności *Carex lachenalii* z pasywnie nałożonymi charakterystykami roślinności na tych poletkach (czarne strzałki)




Modelowanie wzorców współwystępowania gatunków (community assembly rules)



Ordynacja PCA zrobiona dla poletek z różnym procentowym udziałem gatunków roślin diagnostycznych dla łąk zmiennowilgotnych

Identyfikacja bezpośrednich czynników kształtujących skład gatunkowy



Jak inwazja *Solidago canadensis* kształtuje skład gatunkowy roztoczy w gradiencie dekompozycji ścióły liściowej tego gatunku inwazyjnego?

Kiedy ordynacja pośrednia, a kiedy bezpośrednia?

Bezpośrednia:

Do danych składu gatunkowego

Do zmiennych **pasywnie opisujących**
skład gatunkowy

Opis ≠ Wpływ

Do oceny różnic w składzie
gatunkowym przy użyciu
pośrednich danych, np.
charakterystyk roślinności

Do oceny zależności pomiędzy
składem gatunkowym i parametrami
siedliska przy użyciu **danych**
pośrednich, np. ekologicznych liczb
wskaźnikowych

Direct ordination:

Do danych składu gatunkowego

Do zmiennych **aktywnie wpływających**
na skład gatunkowy

Do oceny różnic w składzie
gatunkowym przy użyciu **danych**
bezpośrednich pobranych w terenie

Do oceny zależności pomiędzy
składem gatunkowym i
parametrami siedlisk przy użyciu
danych bezpośrednich pobranych
w terenie

Jak działają ordynacje?

Ordynacja pośrednia:

Pasywnie nałożone wektory opisujące skład gatunkowy **nie mają wpływu na rozmieszczenie punktów** (próbek, poletek badawczych w przestrzeni ordynacyjnej)

Przykłady:

Miary bioróżnorodności, np.:

- Bogactwo gatunkowe
- Różnorodność funkcjonalna
- Różnorodność filogenetyczna

Średnie ważone charakterystyk ugrupowań, np.:

- Ekologiczne liczby wskaźnikowe
- Cechy funkcjonalne

Udział % gatunków na poletkach, np.:

- drzew
- termofilnych
- wskaźnikowych starych lasów, itd.

Ordynacja bezpośrednia:

Aktywnie nałożone wektory kształtują skład gatunkowy **mają wpływ na rozmieszczenie punktów** (próbek, poletek badawczych) w przestrzeni ordynacyjnej

Przykłady:

zasolenie

Zawartość metali ciężkich w glebie

Stosunek zawartości C/N

Wilgotność gleby

temperatura

Dostępność światła

Zawartość fosforu w glebie, itd.

Wskazówki

Bezpośrednie dane mogą być użyte **zarówno** w ordynacji pośredniej, jak i bezpośredniej


Dane pośrednie mogą być użyte **tylko** w ordynacji pośredniej

Niemniej jednak, wszystko zależy od danych, pytań badawczych i stawianych hipotez...

Zawsze zaczynamy od DCA

```
library(vegan)
dca.gradient <- decorana(data)
plot(dca.gradient, disp="sites")
```

Funkcja decorana() zrobi nam ordynację DCA



dca.gradient

```
call:
decorana(veg = carex.fito)

Detrended correspondence analysis with 26 segments.
Rescaling of axes with 4 iterations.
Total inertia (scaled chi-square): 3.1827

      DCA1    DCA2    DCA3    DCA4
Eigenvalues    0.3539 0.1551 0.1114 0.08922
Additive Eigenvalues 0.3539 0.1516 0.1050 0.08316
Decorana values  0.5468 0.2126 0.1657 0.07677
Axis lengths    3.9121 2.4709 2.2656 1.48603
```

Długość gradientu = 3.91 SD

Długość osi DCA1; odległość w linii prostej pomiędzy najbardziej odstającymi punktami w przestrzeni ordynacyjnej wzdłuż osi DCA1

Długość gradientu

Krótszy niż $\sim 3SD$:

Ordynacja pośrednia:

Principal Components Analysis (PCA)
Correspondence Analysis (CA)

Ordynacja bezpośrednia:

Redundancy Analysis (RDA)

Dłuższy niż $\sim 3SD$:

Ordynacja pośrednia:

Detrended Correspondence Analysis (DCA)

Ordynacja bezpośrednia:

Canonical Correspondence Analysis (CCA)

Niezależnie od długości gradientu:

Non-metric Multidimensional Scalling (NMDS) –
tylko wariant pośredni

Pytanie badawcze:

Jak inwazja *Prunus cerasifera* może kształtować/modyfikować skład gatunkowy roślin runa w inicjalnych stadiach sukcesji grądów subkontynentalnych?



Co jest potrzebne? – część 1

Ramka danych z danymi składu gatunkowego poletek badawczych

W naszym przypadku **prunus_vege.csv** zawiera dane % pokrycia gatunków roślin runa na 40 poletkach zlokalizowanych w 4 blokach poletek 5 x 5 m, różniących się % udziałem *P. cerasifera* w drzewostanie inicjalnych grądów (0-90% pokrycia *P. cerasifera*)

#Czas załadować dane

```
prunus_vege<-read.csv("prunus_vege.csv", sep=";", dec=",")# upewnij się, że sep i dec  
ustawione poprawnie
```

Nakarm pakiet vegan poprawnie załadowanymi danymi składu gatunkowego

Najpierw zobaczmy jak wygląda prunus_vege

```
> prunus_vege
```

	plot_id	Ach.mil	Aeg.pod	Agr.eup	Agr.cap	Agr.gig	All.pet	Alo.pra	Ang.syl	Anx.odo	Ant.syl	Tur.gla	Arr.ela
1	G01_4	0.2	0	4.0	0	0.0	0	0.5	0.2	0.0	0.2	0	30
2	G02_4	0.2	0	0.1	0	0.0	0	0.2	0.0	0.0	0.2	0	20
3	G03_4	0.0	0	0.1	0	0.0	0	0.5	0.0	0.0	0.3	0	10
4	G04_3	0.5	0	0.1	0	0.0	0	0.5	0.0	0.5	7.0	0	35
5	G05_4	0.2	5	0.0	0	0.5	0	5.0	0.0	0.0	2.0	0	10
6	G06_2	1.0	0	0.2	0	0.0	0	15.0	0.0	3.0	0.1	0	10
7	G07_3	0.0	0	5.0	0	5.0	0	10.0	0.0	0.0	2.0	0	10
8	G08_3	0.5	0	2.0	0	2.0	0	15.0	0.0	0.0	1.0	0	20

Zasady poprawnego przygotowania danych, wymagane przez pakiet vegan:

Nazwy gatunków w kolumnach

Id poletek badawczych w wierszach

Obfitość występowania, udział, proporcja, liczba osobników, frekwencja gatunków w komórkach

Unikaj myślników, spacji i znaków specjalnych (n.p. ć, ż, ź, ñ, ö, ü, itd.) w nazwach id poletek i gatunków

Jeśli dany gatunek nie był odnotowany w danym poletku, daj „0” – nie zostawiaj pustych komórek (vegan nie cierpi wartości NA)

Bardzo ważne!!!

Vegan pierwszą kolumnę w `prunus_vege` traktuje jako pierwszy gatunek, jaki pojawia się w danych, ale w tabelce to nie jest gatunek, ale plot id

Co trzeba zrobić?

Usunąć pierwszą kolumnę i powiedzieć vegan-owi, że pierwsza kolumna zawiera nazwy wierszy (id poletek):

```
prunus_vege1<- prunus_vege[,-1]  
rownames(prunus_vege1)<-prunus_vege$plot_id
```

Co mieliśmy na początku:

```
> prunus_vege  
plot_id Ach.mil Aeg.pod Agr.eup  
1 G01_4 0.2 0 4.0  
2 G02_4 0.2 0 0.1  
3 G03_4 0.0 0 0.1  
4 G04_3 0.5 0 0.1  
5 G05_4 0.2 5 0.0  
6 G06_2 1.0 0 0.2
```

Co mamy teraz:

```
> prunus_vege1  
Ach.mil Aeg.pod Agr.eup  
G01_4 0.2 0 4.0  
G02_4 0.2 0 0.1  
G03_4 0.0 0 0.1  
G04_3 0.5 0 0.1  
G05_4 0.2 5 0.0  
G06_2 1.0 0 0.2
```

Co potrzeba? – część 2

Ramka danych z charakterystykami roślinności i parametrami siedliska per poletko

W naszym przypadku **prunus_env.csv** zawiera:

- Charakterystyki roślinności, np. typ lasu (veg_type), Prunus cover, species richness, Shannon index, ekologiczne liczby wskaźnikowe per poletko itd. (kolumny 3:20)
- Skład chemiczny gleby per poletko (kolumny 21-31)

#Załadujmy dane i zobaczmy jak wygląda tabelka

```
prunus_env<-read.csv("prunus_env.csv", sep=";", dec=",")  
colnames(prunus_env)
```

```
> colnames(prunus_env)  
[1] "plot_id"      "site_id"      "prunus_cover" "veg_type"     "Faith_PD"     "rich"  
[7] "shan"        "FDis"         "FDiv"         "FEve"         "FRic"         "SLA"  
[13] "seed_mass"   "LDMC"         "plant_height" "light_EIV"    "temp_EIV"     "moisture_EIV"  
[19] "reaction_EIV" "nitrogen_EIV" "Mn"           "Ca"           "Mo"           "Na"  
[25] "K"           "TN"           "S04"          "Cu"           "Cr"           "TOC"  
[31] "P04"  
> |
```

WAŻNE!

Kolejność wyświetlania poletek w prunus_vege musi być **taka sama** jak w tabelce prunus_env

Unikajmy myślników, spacji i znaków specjalnych w nazwach kolumn w prunus_env

Wartości NA nie są dopuszczalne

Jak poradzić sobie z wartościami NA?

`na.omit=TRUE` #najczęściej nie działa

`na.rm=TRUE` #czasem działa

`na.action=na.fail` #działa na modelach

`tabelka.bez.na <- tabelka[complete.cases(tabelka), ]` **#zawsze działa**

Nasze dane są teraz poprawne – zaczynamy od ordynacji pośredniej

Krok 1 – wybierz poprawną metodę ordynacji przy użyciu kryterium długości gradientu

```
#załaduj pakiet  
library(vegan)
```

```
#zrób DCA  
ord.dca<-decorana(prunus_vege1)
```

```
#otwórz obiekt ord.dca
```

```
> ord.dca  
  
call:  
decorana(veg = prunus_vege1)  
  
Detrended correspondence analysis with 26 segments.  
Rescaling of axes with 4 iterations.  
Total inertia (scaled Chi-square): 3.5751  
  
              DCA1    DCA2    DCA3    DCA4  
Eigenvalues    0.3676  0.2543  0.2286  0.2076  
Additive Eigenvalues 0.3676  0.2490  0.2248  0.2086  
Decorana values  0.5198  0.2659  0.1806  0.1465  
Axis lengths    3.2370  2.7316  1.6272  1.9744
```

Długość gradientu = 3.237 SD (więcej niż ~3 SD), więc pozostajemy przy DCA

Ordynacja jest zrobiona, ale jak pokazać ją na obrazku?

Wykres rozrzutu przy użyciu `ggplot()` z pakietu `ggplot2` lub `tidyverse`

Nakarm `ggplot()` danymi

```
class(ord.dca)      #obiekt, w którym siedzi wynik ordynacji  
[1] "decorana "       należy do klasy „decorana”, ale ggplot()  
                    potrzebuje „data.frame”!!!
```

Co trzeba zrobić?

Wyciągnąć współrzędne poletek (site scores) wzdłuż osi DCA1 i DCA2 z obiektu `ord.dca`:


```
sites.dca<-as.data.frame(scores(ord.dca, choices=c(1,2),  
display="sites"))
```

```
> sites.dca
```

	DCA1	DCA2
G01_4	-0.540026026	-1.259537195
G02_4	-1.019032780	-1.027679533
G03_4	-0.188433643	-0.491548887
G04_3	-0.523474794	-0.716460503
G05_4	0.506927480	-0.131703895
G06_2	-0.603077324	0.018454569
G07_3	-0.335290104	-0.245537506
G08_3	-0.117474656	-0.475780520
G09_1	-0.705793552	-0.801796242
G10_1	-0.238338968	-0.054071903
G11_1	-0.648403839	0.691025512
G12_2	0.004279387	-0.006486383
G13_2	0.062282259	0.116542703
G14_2	-0.090048601	0.099954432
G15_4	1.297330494	0.132784312
G16_4	2.218006953	0.165611356

Zróbmy bazowy wykres rozrzutu i spróbujmy coś powiedzieć o danych:

```
prunus.dca<- ggplot(data=sites.dca, aes(x=DCA1, y=DCA2))+  
geom_point()
```



Co widać?

Ładny rozrzut poletek w przestrzeni ordynacyjnej

Brak bardzo wyraźnych outlierów

Brak wyraźnych chmur punktów

Niskie niepodobieństwa składu gatunkowego między poletkami

Kontinuum składu gatunkowego

Aby odkryć więcej dodajmy kolory, zmienmy kropki na inne symbole, itd.

Zmiana kolorów, kształtu i przezroczystości punktów


Zmiana koloru i kształtu punktów w zależności od typu lasu (kolumna veg_type z prunus_env)

```
prunus.dca<- ggplot(data=sites.dca, aes(x=DCA1, y=DCA2))+  
geom_point(aes(x=DCA1, y=DCA2, col=prunus_env$veg_type, shape=prunus_env$veg_type))
```

W razie nakładania się punktów na siebie, zmieńmy ich przezroczystość:

```
prunus.dca<- ggplot(data=sites.dca, aes(x=DCA1, y=DCA2))+  
geom_point(aes(x=DCA1, y=DCA2, col=prunus_env$veg_type, shape=prunus_env$veg_type),  
alpha=0.7)
```

Efekt?



Brzydkie kolory?


Zmiana z ręki:

```
prunus.dca.col <- prunus.dca + scale_colour_manual(values = c("#de2d26", "#3182bd"))
```

Albo automatycznie dla leniwych:

```
prunus.dca.col <- prunus.dca + scale_color_brewer(palette='Set1')
```

<https://colorbrewer2.org/#type=qualitative&scheme=Set1&n=3>




Dodajmy ordi-pająki **ordispiders** - centroidy składu gatunkowego poletek reprezentujących każdy z dwóch typów grądów (średnia współrzędna wzdłuż DCA1 i DCA2 dla całej klasy); średni skład gatunkowy poletek reprezentujących każdy z dwóch typów lasów

#Ekstrakcja średnich współrzędnych per typ lasu:

```
scrs.dca <- cbind(as.data.frame(sites.dca), vege = prunus_env$veg_type)
cent.dca <- aggregate(cbind(DCA1, DCA2) ~ vege, data = scrs.dca, FUN = mean)
segs.dca <- merge(scrs.dca, setNames(cent.dca, c('vege','oDCA1','oDCA2')), by = 'vege', sort = FALSE)
```

#Dodanie linii łączących poletka z centroidami (narysują się ordi-pająki) przy użyciu funkcji `geom_segment()`:

```
prunus.dca.spider<-prunus.dca.col + geom_segment(data = segs.dca, mapping = aes(xend = oDCA1, yend = oDCA2, col=vege), alpha=0.7, linetype = 1)
```



Dlaczego dwie chmury punktów się nakładają? Kontinuum kompozycyjne, ale dlaczego?
Według jakiego gradientu ułożyły się poletka? Według której osi? DCA1, DCA2, a może obie?
Czy oprócz typu lasu inne czynniki mogą nam opisać takie, a nie inne ułożenie punktów?
Jaka jest rola inwazji *P. cerasifera* w opisie różnic składu gatunkowego pomiędzy lasami?
Znajdźmy odpowiedzi robiąc **pasywną projekcję** charakterystyk roślinności

Pasywna projekcja charakterystyk roślinności przy użyciu `vegan::envfit()`

#wybierz kolumny zawierające charakterystyki roślinności plus % pokrycie inwadera

`colnames(prunus_env)`

```
> colnames(prunus_env)
[1] "plot_id"      "site_id"      "prunus_cover" "veg_type"     "Faith_PD"
[6] "rich"         "shan"         "FDIs"         "FDiv"         "FEve"
[11] "FRic"         "SLA"          "seed_mass"    "LDMC"         "plant_height"
[16] "light_EIV"    "temp_EIV"     "moisture_EIV" "reaction_EIV" "nitrogen_EIV"
[21] "Mn"           "Ca"           "Mo"           "Na"           "K"
[26] "TN"           "SO4"          "Cu"           "Cr"           "TOC"
[31] "PO4"
```

#przeprowadź analizę envfit

`envfit.dca<-envfit(ord.dca, prunus_env[,c(3:20)], na.rm=TRUE)`

Wynik?

Lista złożona z kilku poziomów. Ważne dla nas są:

1. Wektory (zmienne numeryczne)

- Koordynaty końców każdego wektora względem DCA1 i DCA2
- r^2 – pato-współczynnik determinacji: jak mocno dany wektor opisuje skład gatunkowy poletek?
- $\text{Pr}(> r)$ – istotność statystyczna każdego wektora

2. Faktory (zmienne kategoryczne):

- Pokazane jako centroid względem DCA1 i DCA2
- r^2
- P-value

Ale pamiętaj!

Cyferki kłamią!

Niektóre wektory istotne statystycznie mogą być nieistotne biologicznie!

Zawsze porównuj z obrazkiem!

```
> envfit.dca

***VECTORS

      DCA1      DCA2      r2 Pr(>r)
prunus_cover  0.93311 -0.35960 0.3053 0.001 ***
Faith_PD      0.00197  1.00000 0.0239 0.572
rich          0.99734  0.07284 0.0710 0.250
shan          0.46414  0.88576 0.2639 0.001 ***
FDIs          0.73712  0.67577 0.1566 0.029 *
FDiv          -0.71226 -0.70192 0.3233 0.002 **
FEve          -0.00258 -1.00000 0.1303 0.074 .
FRic          0.88749  0.46082 0.1127 0.090 .
SLA           0.55299 -0.83319 0.1825 0.019 *
seed_mass     0.08618 -0.99628 0.0979 0.135
LDMC          -0.16321  0.98659 0.1227 0.080 .
plant_height  0.21064 -0.97756 0.2453 0.006 **
light_EIV     -0.95258 -0.30428 0.7618 0.001 ***
temp_EIV      -0.40219  0.91555 0.3169 0.002 **
moisture_EIV  0.85014 -0.52656 0.3692 0.001 ***
reaction_EIV  0.45798 -0.88896 0.3091 0.001 ***
nitrogen_EIV  0.70455 -0.70965 0.5403 0.001 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Permutation: free
Number of permutations: 999

***FACTORS:

Centroids:

      DCA1      DCA2
veg_typefresh_decid -0.2317 -0.3059
veg_typefresh_mixed  0.2254  0.2975

Goodness of fit:
      r2 Pr(>r)
veg_type 0.2202 0.001 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Permutation: free
Number of permutations: 999
```

Zwizualizujemy wynik analizy envfit – wektory jako strzałki na obrazku

#Ekstrakcja koordynatów początków i końców strzałek względem DCA1 i DCA2


#Zrobienie tabelki jadalnej dla ggplot2():

```
gg.arrows.dca<-data.frame(DCA1 = envfit.dca$vectors$arrows[,1],  
DCA2 =envfit.dca$vectors$arrows[,2],  
lab=rownames(envfit.dca$vectors$arrows),  
p=envfit.dca$vectors$pvals)
```

#envfit.dca jest listą
złożoną z wielu
poziomów i
podpoziomów

#Dodaj strzałki do obrazka przy użyciu funkcji geom_segment() oraz popracuj nad estetyką strzałek:

```
prunus.dca.envfit<-  
prunus.dca.spider + geom_segment(data=gg.arrows.dca, aes(x=0, xend=DCA1, y=0,  
yend=DCA2), arrow = arrow(length = unit(0.2,'cm')), color='black', linewidth=1)
```



Pamiętaj! – dodanie wektorów do ordynacji pośredniej nie zmienia konfiguracji ułożenia punktów


Następny krok: dodanie nazw strzałek

Dodaj nazwy strzałek

`#ggrepel::geom_text_repel` lepszy niż `geom_text()` – zapobiega nakładaniu się na siebie podpisów strzałek umieszczonych na obrazku bardzo blisko siebie

```
library(ggrepel)
prunus.dca.env.names<- prunus.dca.envfit + geom_text_repel(data=gg.arrows.dca,
aes(x=DCA1,y=DCA2, label=lab), max.overlaps=100, col="black", cex=5)
```



Wrózenie z punktów



Dobre rady

Patrz mniej na istotność statystyczną

Patrz więcej na istotność biologiczną



	DCA1	DCA2	r ²	Pr(>r)	
prunus_cover	0.93311	-0.35960	0.3053	0.001	***
Faith_PD	0.00197	1.00000	0.0239	0.572	
rich	0.99734	0.07284	0.0710	0.250	
shan	0.46414	0.88576	0.2639	0.001	***
FDis	0.73712	0.67577	0.1566	0.029	*
FDiv	-0.71226	-0.70192	0.3233	0.002	**
FEve	-0.00258	-1.00000	0.1303	0.074	.
FRic	0.88749	0.46082	0.1127	0.090	.
SLA	0.55299	-0.83319	0.1825	0.019	*
seed_mass	0.08618	-0.99628	0.0979	0.135	
LDMC	-0.16321	0.98659	0.1227	0.080	.
plant_height	0.21064	-0.97756	0.2453	0.006	**
light_EIV	-0.95258	-0.30428	0.7618	0.001	***
temp_EIV	-0.40219	0.91555	0.3169	0.002	**
moisture_EIV	0.85014	-0.52656	0.3692	0.001	***
reaction_EIV	0.45798	-0.88896	0.3091	0.001	***
nitrogen_EIV	0.70455	-0.70965	0.5403	0.001	***

Faith_PD statystycznie nieistotny, ale prawdopodobnie biologicznie ważny dla opisu składu gatunkowego poletek fresh_mixed

nitrogen_EIV statystycznie istotny, ale niska moc biologiczna w opisie wzorców

Podobnie zresztą prunus_cover

Wróćmy do głównego problemu badawczego...

Z obrazka wynika, że inwazja *P. cerasifera* ma niewielką moc w opisie różnic w składzie gatunkowym pomiędzy lasami


Jak pokazać zatem efekt inwazji?

#zmieńmy rozmiar punktów w zależności od pokrycia *P. cerasifera* na poletkach:

1. Wróć do obrazka prunus.dca z kolorami i symbolami
2. Dodaj argument „size” w geom_point aesthetics:

```
prunus.dca<- ggplot(data=sites.dca, aes(x=DCA1, y=DCA2))+  
geom_point(aes(x=DCA1, y=DCA2, col=prunus_env$veg_type, shape=prunus_env$veg_type,  
size=prunus_env$prunus_cover), alpha=0.7)
```

3. Przeklikaj jeszcze raz kod od **prunus.dca** do **prunus.dca.env.names**



#Jeśli nie lubisz szarego tła :

```
library(ggthemes)
prunus.dca.env.names + theme_few()
```

Nadal efekt inwazji słabo widoczny...

Pomóc może dodanie współrzędnych gatunków do obrazka

#Wyciąganie współrzędnych gatunków z obiektu, w którym siedzi wynik analizy DCA:


```
species.dca<-as.data.frame(scores(ord.dca, choices=c(1,2), display="species"))
```

#Aby nie zaśmiecać, można pokazać tylko gatunki, które wystąpiły powyżej 3 razy:

```
data.sums <-as.data.frame(colSums(decostand(prunus_vege[,-1], "pa")))  
names(data.sums)<-c("sum_occ")  
species.dca$spec<-rownames(species.dca)  
species.dca$sum_occ<-data.sums  
sub.dca<-as.data.frame(subset(species.dca, species.dca$sum_occ>2))
```

#Dodaj do obrazka etykiety z nazwami gatunków przy użyciu `geom_text_repel`:

```
prunus.dca.species<-  
prunus.dca.env.names + geom_text_repel(data=sub.dca, aes(x=DCA1, y=DCA2,  
label=rownames(sub.dca)), max.overlaps=100, cex=3)+theme_few()
```



To jeszcze nie koniec...

Poletka zgrupowane były w 4 bloki powierzchni, czyli efekty losowe związane z układem badawczym

Jak pokazać ten efekt losowy na obrazku?


Jedno z rozwiązań: dodanie elips z 95% przedziałem ufności

```
prunus.dca.ellipse<- prunus.dca.species+  
stat_ellipse(aes(x=DCA1, y=DCA2, col=prunus_env$site_id),  
alpha=0, geom="polygon", level=.95, size=1, linetype="dashed")+  
scale_colour_manual(values = c("#de2d26", "#3182bd", "#006d2c",  
"#e7298a", "#ec7014", "#54278f"))+theme_few()
```

#Uwaga:

- `scale_color_manual` ma 6 kolorów; pierwsze dwa kolorują lasy (bo lasy jako pierwsze w ggplot), a pozostałe 4 są do pokolorowania elips (jedna elipsa per jeden blok)

- Dodanie nowej skali kolorów automatycznie zastąpi istniejącą skalę





Co jeśli?

Wyobraźmy sobie, że gradient był krótszy niż $\sim 3SD$

Jaka metoda wtedy?

Zgodnie ze sztuką, zaczynamy od PCA:

```
ord.pca<-rda(prunus_vege1)
```

Ważność osi PC1 i PC2 w opisie składu gatunkowego

Tylko w przypadku PCA można zobaczyć, jaki % zmienności składu gatunkowego wyjaśnia nam oś PC1, a ile PC2

Aby to zrobić, otworzymy obiekt, w którym siedzi PCA i policzymy ten %:

```
> ord.pca
Call: rda(x = prunus_vege1)

              Inertia Rank
Total              1095
Unconstrained      1095   39
Inertia is variance

Eigenvalues for unconstrained axes:
  PC1  PC2  PC3  PC4  PC5  PC6  PC7  PC8
411.9 235.1  99.2  75.3  50.7  40.5  32.6  28.8
(Showing 8 of 39 unconstrained eigenvalues)
```

Total inertia = 1095.0

Eigenvalue PC1 = 411.9

Eigenvalue PC1/Total inertia = 0.376
(~38%)

Total inertia = 1095.0

Eigenvalue PC2 = 235.1

Eigenvalue PC2/Total inertia = 0.215
(~22%)

Jak pokazać PCA na obrazku?

Tak samo jak DCA

Ale zanim to zrobisz:

Zrozumiałe nazywaj obiekty ggplot (unikniesz bałaganu w kodzie)

Zamień „DCA” na „PC” w całym kodzie do PCA

Dla wizualizacji, zrobmy bazowy scatter plot dla PCA:

#Wyciągnij współrzędne poletek


```
sites.pca<-as.data.frame(scores(ord.pca, choices=c(1,2), display="sites"))
```

#Zrób obrazek


```
prunus.pca<-ggplot(data=sites.pca, aes(x=PC1, y=PC2))+ geom_point(aes(x=PC1, y=PC2,  
col=prunus_env$veg_type), size=3 , alpha=0.7)+  
scale_colour_manual(values = c("#de2d26", "#3182bd"))+  
theme_few()
```

Ok, czy nie OK?

Jeśli PCA nie pasuje, to dlaczego?



Efekt podkowy – artefakt w PCA



Pojawia się, gdy gradient
wzdłuż PC1 za długi

PCA nie wie co zrobić z
częścią poletek odstających
od reszty, a że jest ich
trochę to upycha je **na siłę**
na obu końcach gradientu

Co zrobić, gdy PCA generuje podkowę?

Ordynacja CA

#zrób CA


```
ord.ca<-cca(prunus_vege1)
```

#ekstrakcja współrzędnych poletek badawczych (punktów)


```
sites.ca<-as.data.frame(scores(ord.ca, choices=c(1,2), display="sites"))
```

#Pokaż na obrazku


```
prunus.ca<-ggplot(data=sites.ca, aes(x=CA1, y=CA2))+  
  geom_point(aes(x=CA1, y=CA2, col=prunus_env$veg_type), size=3 , alpha=0.7)+  
  scale_colour_manual(values = c("#de2d26", "#3182bd"))+  
  theme_few()
```

Efekt łuku– artefakt w CA



Efekt trójkąta – artefakt w DCA



98% recenzentów to kupi, ale słynny recenzent numer 2 na może doszukać się tu artefaktu (np. prof. Werner Ulrich)

Co wtedy?

Transformacja danych - `vegan::decostand()` (wrócimy to tego później)

Albo każe zrobić ordynację NMDS

Non Metric Multidimensional Scalling (NMDS)

Mapa pokazująca rozrzut punktów w przestrzeni ordynacyjnej

Tak jak na każdej mapie, odległości pomiędzy poletkami można mierzyć – im dalej są od siebie poletka tym są bardziej niepodobne do siebie względem składu gatunkowego

Odległości między poletkami można mierzyć za pomocą wielu metod – zobacz pomoc do funkcji `vegan::vegdist()`

Dłuższe odległości = większe niepodobieństwa składu gatunkowego poletek

W praktyce, nie potrzebujemy znajomości matematyki kryjącej się za metodami obliczania niepodobieństw

Bawimy się różnymi metodami odległości i wybieramy tę, która według nas najlepiej pasuje do naszych danych

?vegdist

Usage

```
vegdist(x, method="bray", binary=FALSE, diag=FALSE, upper=
        na.rm = FALSE, ...)
```

Arguments

- x** Community data matrix.
- method** Dissimilarity index, partial match to "manhattan", "euclidean", "canberra", "clark", "bray", "kulczynski", "jaccard", "gower", "altGower", "morisita", "horn", "mountford", "raup", "binomial", "chao", "cao", "mahalanobis", "chisq", "chord", "hellinger", "aitchison", or "robust.aitchison".
- binary** Perform presence/absence standardization before analysis using decostand.
- diag** Compute diagonals.
- upper** Return only the upper diagonal.
- na.rm** Pairwise deletion of missing observations when computing dissimilarities.
- ...** Other parameters. These are ignored, except in `method = "gower"` which accepts `range.global` parameter of decostand, and in `method = "aitchison"`, which accepts `pseudocount` parameter of decostand used in the `clr` transformation.

Zróbmy NMDS

#zasiejmy ziarno

set.seed(45435) #ważne, bo NMDS działa na liczbach pseudolosowych, zasianie ziarna gwarantuje powtarzalność wyników

#zrób NMDS (Bray-Curtis dissimilarity jako domyślna metoda odległości)

```
ord.mds<-metaMDS(prunus_vege1, dist="bray")
```


#ekstrakcja współrzędnych poletek

```
sites.mds<-as.data.frame(scores(ord.mds, choices=c(1,2), display="sites"))
```

#obrazek

```
prunus.mds<-ggplot(data=sites.mds, aes(x=NMDS1, y=NMDS2))+  
geom_point(aes(x=NMDS1, y=NMDS2, col=prunus_env$veg_type), size=3, alpha=0.7)+  
scale_colour_manual(values = c("#de2d26", "#3182bd"))+ theme_few()
```

#reszta kodu taka sama, jak przy DCA



...usunęliśmy artefakt DCA (efekt trójkąta)...

...ale czy DCA nie pokazywało różnic lepiej?

Nie zawsze jest tak różowo...

Najczęściej pracujemy z danymi, które zawierają znaczny szum wynikający z wielu losowych czynników wpływających na gatunki w środowisku – czynników, których albo nie badamy, ponieważ ich wpływ jest nieznany, albo nie jesteśmy świadomi ich istnienia.

W rezultacie rzadko uzyskujemy wynik, który jest od razu biologicznie interpretowalny

...Generują się outliery

...Nie potrafimy znaleźć wyjaśnienia uzyskanego ułożenia punktów

...Nie uzyskujemy zakładanego na początku ułożenia punktów, a przecież te różnice widzieliśmy już w terenie podczas zbioru danych!

Dlatego gdy zawodzi PCA, CA, DCA i NMDS zrobione na danych surowych, z pomocą przyjść może **transformacja danych**



Transformacja danych

```
vegan::decostand()
```

Zastosuj przed zrobieniem ordynacji

Dużo różnych metod – nie ma lepszej i gorszej, zależy od danych
?decostand

Najczęściej: normalization, log, presence-absence (pa)

Jak to zrobić?





```
prunus_deco<-decostand(prunus_vege1, method="normalize")# najpierw  
transformacja (tutaj normalizacja)
```


```
ord.dca.norm<-decorana(prunus_deco)#zrób ordynację
```

```
#Wyciągnij współrzędne
```

```
sites.dca.deco<-as.data.frame(scores(ord.dca.norm, choices=c(1,2), display="sites"))
```

```
#Zrób obrazek
```





Ordynacje pośrednie Plan działania

- Na każdym etapie:
- Obrazek (punkty, gatunki, envfit)
 - Próba interpretacji

Ordynacja bezpośrednia

Oprócz charakterystyk roślinności (kolumny 3:20), `prunus_env` zawiera dane składu chemicznego gleby zmierzone bezpośrednio (kolumny 21:30)

Ponieważ te zmienne nie opisują składu gatunkowego, a raczej aktywnie kształtują/wpływają na kompozycję gatunkową, mamy podstawę do zrobienia ordynacji bezpośredniej

Podobnie, możemy uznać, że przecież wzrastający % udział inwazyjnej *Prunus* w drzewostanie może aktywnie wpływać na skład gatunkowy runa!!!

Diagram ordynacji bezpośredniej – co zawiera?

Punkty jako poletka

Niepodobieństwa składu gatunkowego


Kontinuum/dyskontinuum kompozycyjne

Wektory (strzałki) nałożone aktywnie –
co to znaczy?

Że dodanie strzałek wpływa na
rozmieszczenie poletek
(punktów) w przestrzeni
ordynacyjnej

Wygląda jak regresja
wielokrotna, ale
przewiduje skład
gatunkowy

Dlatego nazywana ordynacją i
regresją w jednym



RDA czy CCA?

Zawsze zaczynamy od oceny długości gradientu

```
vegan::decorana()
```

W naszym przypadku już wiemy, że było więcej niż 3SD więc wybieramy CCA:

```
ord.cca.global<-cca(prunus_vege1~prunus_cover+Ca+Mo+Na+K+TN+SO4+Cu+Cr+TOC+PO4,  
data=prunus_env)
```

#Jeśli gradient krótszy niż 3SD, wybieramy RDA:


```
ord.rda.global<-rda(prunus_vege1~prunus_cover+Ca+Mo+Na+K+TN+SO4+Cu+Cr+TOC+PO4,  
data=prunus_env)
```

Za dużo predyktorów i współliniowość

Im więcej predyktorów tym ordynacja bezpośrednia staje się coraz bardziej pośrednia, bo dodanie kolejnych strzałek blokuje możliwości innych wariantów ułożeń punktów

Zaczynamy od macierzy korelacji i wywalamy to, co albo jest bez sensu, albo mocno skorelowane

```
library(corrplot)
corrplot(cor(prunus_env[,c(3, 21:31)]))
```



Współliniowość - automatyczna selekcja zmiennych

vegan::step()

Na podstawie AIC

step(ord.cca.global)

Finalny model CCA składa się tylko z dwóch predyktorów:

K

TN

Straciliśmy prunus_cover

Niebezpieczne narzędzie – nie mamy na nim żadnej kontroli

```
      Df    AIC
- Mo    1 236.99
- K      1 237.01
<none>   237.06
- PO4    1 237.07
- Cr     1 237.31
- TN     1 238.10
```

```
Step: AIC=236.99
prunus_vege1 ~ K + TN + Cr + PO4
```

```
      Df    AIC
- Cr    1 236.06
- PO4   1 236.74
- K      1 236.86
<none>   236.99
- TN     1 237.80
```

```
Step: AIC=236.06
prunus_vege1 ~ K + TN + PO4
```

```
      Df    AIC
- PO4    1 235.87
- K      1 235.87
<none>   236.06
- TN     1 236.80
```

```
Step: AIC=235.87
prunus_vege1 ~ K + TN
```

```
      Df    AIC
<none>   235.87
- K      1 235.96
- TN     1 236.74
Call: cca(formula = prunus_vege1 ~ K + TN, data = prunus_env)
```

```
          Inertia Proportion Rank
Total          3.5751      1.0000
Constrained    0.3965      0.1109    2
Unconstrained  3.1787      0.8891   37
Inertia is scaled Chi-square
```

```
Eigenvalues for constrained axes:
      CCA1    CCA2
0.24740 0.14907
```

```
Eigenvalues for unconstrained axes:
      CA1    CA2    CA3    CA4    CA5    CA6    CA7    CA8
0.4431 0.3066 0.2577 0.2547 0.2100 0.1753 0.1495 0.1454
(Showing 8 of 37 unconstrained eigenvalues)
```


Współliniowość - Variance inflation factors (VIF)

vif.cca(ord.cca.global)

Procedura:

Zrób CCA ze wszystkimi zmiennymi

Policz VIFy

Usuń jeden predyktor z najwyższą wartością VIF

Zrób CCA bez tego predyktora

Policz VIF-y jeszcze raz i usuń kolejny predyktor o najwyższej wartości VIF

Zapętl tę procedurę tak długo, aż otrzymasz zestaw zmiennych, których VIF-y są mniejsze niż 5(10)

```
> vif.cca(ord.cca.global)
```

prunus_cover	Ca	Mo	Na	K
16.493400	14.260260	15.990311	5.584096	18.947110
TN	SO4	Cu	Cr	TOC
18.587405	1.565606	10.448299	15.245788	8.050831
PO4				
9.428835				

Finalny model CCA w naszym przypadku

```
> vif.cca(ord.cca.final)
```

prunus_cover	Ca	Mo	Na	SO4	PO4
1.501553	1.556886	1.263237	1.190214	1.177441	1.031233

```
ord.cca.final<-cca(prunus_vege1~prunus_cover+Ca+Mo+Na+SO4+PO4,  
data=prunus_env)
```

Które predyktory najmocniej wpływają na skład gatunkowy runa na poletkach?

PERMANOVA

```
anova(ord.cca.final, by="terms")
```

```
> anova(ord.cca.final, by="terms")
Permutation test for cca under reduced model
Terms added sequentially (first to last)
Permutation: free
Number of permutations: 999

Model: cca(formula = prunus_veget ~ prunus_cover + Ca + Mo + Na + SO4 + PO4, data = prunus_env)
      Df ChiSquare      F Pr(>F)
prunus_cover  1    0.21886 2.5390 0.001 ***
Ca            1    0.09671 1.1219 0.304
Mo            1    0.08141 0.9445 0.546
Na            1    0.09947 1.1539 0.241
SO4           1    0.07185 0.8336 0.751
PO4           1    0.16227 1.8825 0.007 **
Residual     33    2.84457
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Ale pamiętaj:

Istotność biologiczna

Wielkość efektów

P-values tylko jako kryterium pomocnicze w ocenie wzorców

Zawsze rób obrazek

Nie ufaj cyferkom

CCA na obrazku

#Wyciągnij współrzędne poletek (punkty)

```
sites.cca<-as.data.frame(scores(ord.cca.final, choices=c(1,2), display="sites"))
```

#Wyciągnij współrzędne gatunków (subset z gatunkami, które wystąpiły więcej niż 3 razy)

```
species.cca<-as.data.frame(scores(ord.cca.final, choices=c(1,2), display="species"))
```

```
species.cca$sum_occ<-data.sums
```

```
sub.cca<-as.data.frame(subset(species.cca, species.cca$sum_occ>2))
```

#Wyciągnij współrzędne aktywnych wektorów (strzałki, biplot scores)


```
biplot.cca<-as.data.frame(scores(ord.cca.final, choices=c(1,2), display="bp"))
```


#ordi-pajaki:

```
scrs.cca <- cbind(as.data.frame(sites.cca), vege = prunus_env$veg_type)
cent.cca <- aggregate(cbind(CCA1, CCA2) ~ vege, data = scrs.cca, FUN = mean)
segs.cca <- merge(scrs.cca, setNames(cent.cca, c('vege','oCCA1','oCCA2')), by = 'vege', sort = FALSE)
```

#ggplot

```
ggplot(data=sites.cca, aes(x=CCA1, y=CCA2))+
geom_point(aes(x=CCA1, y=CCA2, col=prunus_env$veg_type, size=prunus_env$prunus_cover),
alpha=0.7)+
scale_colour_manual(values = c("#de2d26", "#3182bd"))+
geom_segment(data = segs.cca, mapping = aes(xend = oCCA1, yend = oCCA2, col=vege),
alpha=0.7, linetype = 1)+
geom_segment(data=biplot.cca, aes(x=0, xend=CCA1, y=0, yend=CCA2), arrow = arrow(length =
unit(0.2,'cm'))), color='black', linewidth=1)+
geom_text_repel(data=biplot.cca, aes(x=CCA1,y=CCA2, label=rownames(biplot.cca)),
max.overlaps=100, color="black", cex=5)+
geom_text_repel(data=sub.cca, aes(x=CCA1, y=CCA2, label=rownames(sub.cca)),
max.overlaps=100, cex=3)+
theme_few()
```





Ordynacje bezpośrednie

Plan działania

Na każdym etapie:

- Obrazek (punkty, gatunki, envfit)
- Próba interpretacji

Po co komu clustering (tworzenie dendrogramów)?

Według niektórych badaczy najprostsza metoda ordynacji

Dzieli zbiór danych na grupy

Ułatwia wyodrębnienie zasadniczych cech przedmiotów badania na podstawie podobieństwa/niepodobieństwa pomiędzy nimi

Umożliwia odkrycie nieznanej struktury danych – analizy bardzo przydatne dla taksonomów przy konstrukcji drzew filogenetycznych oraz dla fitosocjologów

Niepodobieństwo
składu gatunkowego
roślin runa pomiędzy
poletkami:

- Z wyciętymi martwymi świerkami
- Z niewyciętymi martwymi świerkami
- Z niezaburzonym drzewostanem




Fig. 2 Results of hierarchical clustering analysis with a criterion of Ward's minimum variance showing the Bray–Curtis compositional dissimilarities between vegetation types studied

Szybki dendrogram w R

#Potrzebujemy dane składu gatunkowego, trzymane w obiekcie prunus_vege1

#Potem tworzymy macierz niepodobieństwa składu gatunkowego poletek (wyliczy niepodobieństwo każdego poletka z każdym:

```
prunus_dist<-vegdist(prunus_vege1, method="bray")
```

#funkcja „vegdist” ma argument „method”

?vegdist

Usage

```
vegdist(x, method="bray", binary=FALSE, diag=FALSE,  
        na.rm = FALSE, ...)
```

Arguments

x	Community data matrix.
method	Dissimilarity index, partial match to "manhattan", "euclidean", "canberra", "clark", "bray", "kulczynski", "jaccard", "gower", "altGower", "morisita", "horn", "mountford", "raup", "binomial", "chao", "cao" or "mahalanobis".

#method= "bray" najczęściej używany w ekologii roślinności (niepodobieństwo Bray-Curtisa)

#method= " euclidean " to odległość euklidesowa – najpopularniejsza w biologii


#W obiekcie prunus_dist siedzi macierz niepodobieństwa pomiędzy poletkami (pokazano tylko początek macierzy bo jest to obiekt bardzo duży)

```
> prunus.dist
      G01_4  G02_4  G03_4  G04_3  G05_4  G06_2  G07_3  G08_3  G09_1
G02_4 0.6027586
G03_4 0.5735736 0.5762987
G04_3 0.3513166 0.5621139 0.4667662
G05_4 0.6197880 0.6714829 0.4720134 0.5738397
G06_2 0.6323617 0.6103732 0.4955571 0.5189573 0.5808538
G07_3 0.5672170 0.5576441 0.4289581 0.5102760 0.5105701 0.3322386
G08_3 0.4525939 0.5091947 0.5325565 0.4655582 0.4708171 0.3904867 0.3439386
G09_1 0.5152186 0.6332748 0.6224040 0.3980154 0.6495215 0.7254902 0.6999488 0.5863495
G10_1 0.4301994 0.6725076 0.5862069 0.4335982 0.5888889 0.5344645 0.5276170 0.3602550 0.5119284
G11_1 0.6462428 0.6920245 0.6441799 0.6534254 0.5836991 0.4207415 0.5628998 0.5002693 0.6658279
G12_2 0.6198867 0.7165883 0.6513494 0.6453634 0.6437414 0.4848837 0.3971182 0.4498834 0.7843987
G13_2 0.7271523 0.8553191 0.7600619 0.7468688 0.6610909 0.5880561 0.5483092 0.5149664 0.8075835
G14_2 0.5950054 0.7129736 0.5825123 0.5154137 0.5946104 0.4181450 0.3853119 0.4575927 0.7093854
G15_4 0.8198490 0.8962372 0.8569682 0.8796346 0.6916812 0.7430730 0.7250000 0.6607774 0.8900995
G16_4 0.8541329 0.9154769 0.8714023 0.9031216 0.7144522 0.8647830 0.8187281 0.7886754 0.9165085
G17_3 0.5190931 0.6205584 0.6104252 0.4177065 0.6482803 0.5473160 0.5444566 0.5174709 0.6006208
G18_4 0.5823337 0.4971165 0.6435644 0.5730581 0.5314891 0.4432570 0.4949495 0.3431922 0.7187948
G19_4 0.6357928 0.7327443 0.7861784 0.5672576 0.7162162 0.6983350 0.7044239 0.5603533 0.5387454
G20_1 0.5188199 0.6956056 0.7276888 0.4921439 0.6111415 0.6223176 0.6439394 0.4495939 0.3549258
G21_1 0.5248672 0.7087773 0.7485159 0.4937440 0.6735537 0.6194369 0.6048714 0.4949955 0.2689003
G22_1 0.6550725 0.7725888 0.8142549 0.5512759 0.6795866 0.7337574 0.7337545 0.5648612 0.4078212
G23_2 0.7439773 0.7283094 0.6893102 0.6864407 0.6417760 0.4759786 0.4626602 0.5499109 0.7649537
G24_3 0.7214248 0.8618754 0.6043295 0.6790254 0.6025200 0.5735586 0.5293537 0.4671315 0.7567820
G25_2 0.7629797 0.8325359 0.7528958 0.7661608 0.6334759 0.5911718 0.4942649 0.5566087 0.7466732
```

Tworzenie obrazka

#Funkcja `hclust` z pakietu bazowego tworzy drzewko w oparciu o macierz niepodobieństwa, która znajduje się w obiekcie `prunus_dist`:

```
hc_prunus<-hclust(prunus_dist)  
plot(hc_prunus)
```





BSS
BIAŁOWIESKA SZKOŁA STATYSTYKI