



BIAŁOWIESKA SZKOŁA STATYSTYKI

Modele liniowe z efektami stałymi i losowymi

	spec	zone	plot.ID	AB	BR	total.volume	age	plot.area	basal.area	density	DBH	H
1	Picea	lowland	28	188.8861	20.7113	407.99	45	0.1056	38.31	1089.0	20.65	20.19
2	Picea	lowland	46	159.8177	21.2291	345.66	39	0.2115	31.46	595.7	25.51	21.66
3	Picea	lowland	51	270.9730	26.2697	566.35	78	0.2500	40.46	456.0	32.81	30.76
4	Picea	lowland	69	259.1293	34.0499	547.40	113	0.7400	35.23	139.2	55.30	35.66
5	Picea	lowland	71	258.1590	25.8864	598.48	66	0.2400	44.31	462.5	34.29	27.67
6	Picea	lowland	73	345.2840	33.9507	779.26	98	0.4900	49.68	271.4	47.86	35.33
	longitude	latitude										
1	15.09219	52.88818										
2	14.41213	53.66229										
3	14.49006	53.89057										
4	16.68680	54.07632										
5	16.72052	54.20158										
6	15.99423	53.69993										

```
drzewa<-read.csv('sprucefir.csv', sep=,;')
```

Zbiór danych: drzewa (biomasa świerków)

Spec – gatunek Picea

Zone – strefa lowland/highland plot.ID – numer poletka

N, E – koordynaty

age – wiek [lata]

density– zagęszczenie [szt. ha⁻¹]

basal.area – pole powierzchni drzew [m² ha⁻¹]


H – wysokość górna d-stanu [m]

DBH – średnia pierśnica [cm]


Total.volume – miąższość [m³ ha⁻¹]

AB –biomasa części nadziemnej [t ha⁻¹]

BR –biomasa gałęzi [t ha⁻¹]




```
ggplot(drzewa, aes(x=total.volume, y=AB))+geom_point()
```



```
ggplot(drzewa, aes(x=age, y=BR))+geom_point()
```

```
ggplot(drzewa, aes(x=total.volume,y=AB))+geom_point()  
+geom_smooth(method='lm')
```



Model liniowy


$$y=a*x+b$$

a - współczynnik kierunkowy, slope, regression coefficient, beta

nachylenie linii regresji (kąt – w zasadzie jego tangens)

b - wyraz wolny, intercept

punkt przecięcia z osią Y, położenie linii



Biologiczne znaczenie - effect size!

<https://www.amstat.org/asa/files/pdfs/P-ValueStatement.pdf>

<https://amstat.tandfonline.com/doi/pdf/10.1080/00031305.2016.1154108?needAccess=true>

Ronald L. Wasserstein, Allen L. Schirm & Nicole A. Lazar (2019) Moving to a World Beyond “ $p < 0.05$ ”, The American Statistician, 73:sup1, 1-19, DOI: 10.1080/00031305.2019.1583913

nieistotny biologicznie efekt (3%) - $p < 0.00001$ przy $n=300$

istotny efekt (800%) - $p > 0.05$ przy $n=3$

Ok, mamy linię trendu, wygląda ładnie

- Chcemy model, czyli matematyczne odwzorowanie zależności
- Funkcja `lm()` – model liniowy, prosta $y=ax+b$
- `modelAB<-lm(AB~total.volume, data=drzewa)`
- `summary(modelAB)`

Postać modelu

```
call:
lm(formula = AB ~ total.volume, data = drzewa)
```

Rozkład reszt

```
Residuals:
    Min       1Q   Median       3Q      Max
-32.831  -8.367  -1.388   10.735   23.284
```

Współczynniki

```
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  16.63766    6.50448   2.558   0.0179 *
total.volume   0.41061    0.01258  32.645  <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Wyraz wolny (b)

Slope (a)

```
Residual standard error: 14.71 on 22 degrees of freedom
Multiple R-squared:  0.9798,    Adjusted R-squared:  0.9789
F-statistic: 1066 on 1 and 22 DF,  p-value: < 2.2e-16
```

Współczynnik determinacji R^2

Ok, mamy linię trendu, wygląda ładnie

- Chcemy model, czyli matematyczne odwzorowanie zależności
- Funkcja `lm()` – model liniowy, prosta $y=ax+b$
- `modelAB<-lm(AB~total.volume, data=drzewa)`
- `summary(modelAB)`

$$\text{Biomasa} = \text{total.volume} \times 0.41061 + 16.63766$$

Postać modelu

Rozkład reszt

Współczynniki

Wyraz wolny (b)

Slope (a)

```
call:
lm(formula = AB ~ total.volume, data = drzewa)


Residuals:
    Min       1Q   Median       3Q      Max
-32.831  -8.367  -1.388   10.735   23.284

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  16.63766    6.50448   2.558   0.0179 *
total.volume   0.41061    0.01258  32.645 <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 14.71 on 22 degrees of freedom
Multiple R-squared:  0.9798,    Adjusted R-squared:  0.9789
F-statistic: 1066 on 1 and 22 DF,  p-value: < 2.2e-16
```

Współczynnik determinacji R^2

a tutaj? lepszy czy gorszy?




Czy model jest dobrze dopasowany?

- Na oko jest ok
- Co powinniśmy sprawdzić i o czym nam to mówi?
 - Rozkład reszt (residuów)
 - Dopasowanie modelu
 - Niepewność oszacowania
 - Obserwacje odstające
 - Ilość wyjaśnianej zmienności

Rozkład reszt residuals(modelAB)

- Reszty – różnica między wartością wymodelowaną a rzeczywistą
- Powinien być normalny
- Sprawdźmy histogram:
`hist(residuals(modelAB))`







```
> residuals(modelAB)
```

1	2	3	4	5	6	7	8
4.7239596	1.2488361	21.7867739	17.7241197	-4.2201023	8.6749519	17.8391908	-5.2747250
9	10	11	12	13	14	15	16
16.9140367	3.8583761	-12.9628460	-14.9769911	1.5625882	-6.8348504	-14.4923772	-3.1304184
17	18	19	20	21	22	23	24
19.0096862	-18.2628225	23.2836671	0.3536513	-32.8305242	-4.6045981	-13.2535055	-6.1360769


Diagnostyka

```
par(mfrow=c(2,2))  
#4 obrazki na jednym  
plot(modelAB)
```




Diagnostyka

- Reszty vs wartości wymodelowane
- Czerwona linia powinna być prosta
- Trend – problem!
- Tutaj reszty rosną a potem maleją – lekki problem




Diagnostyka

- Heteroskedastyczność
- Gdy błąd rośnie wraz z wartością wymodelowaną
- Problem przy modelach z których chcemy coś obliczyć




Diagnostyka

- Standaryzowane reszty vs kwantyle wartości wymodelowanych
- Punkty powinny być w linii
- Podpisane numery wierszy z najbardziej odstającymi wartościami
- Generalnie ok




Diagnostyka

- Standaryzowane reszty vs wartości wymodelowane
- Powinna być prosta
- Podpisane numery wierszy z najbardziej odstającymi wartościami
- Generalnie ok



Diagnostyka

- Standaryzowane reszty vs dźwignia
- Dźwignia – wpływ na model
- Co robi problemy:
 - Duża dźwignia (wpływowe outliery)
 - Duże reszty (outliery bez wpływu)



Prostszy sposób oceny jakości modeli


- pakiet DHARMa

```
library(DHARMa)
```

```
plot(simulateResiduals(modelAB))
```


<https://cran.r-project.org/web/packages/DHARMa/vignettes/DHARMa.html>

Test rozkładu reszt



DHARMa residual

Test trendów w resztach



przykład poprawnego dopasowania

- Mniejsze R^2
- Spełnione założenia


```
> plot(simulateResiduals(modelABage))
> modelABage<-lm(AB~basal.area, data=drzewa)
> summary(modelABage)

Call:
lm(formula = AB ~ basal.area, data = drzewa)

Residuals:
    Min       1Q   Median       3Q      Max
-61.243 -26.975  -4.549  32.460  56.288

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  -19.383     19.467  -0.996   0.33
basal.area     6.435      0.516  12.471 1.89e-11 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 36.42 on 22 degrees of freedom
Multiple R-squared:  0.8761,    Adjusted R-squared:  0.8704
```







O czym mówi R^2

- Ilość zmienności wyjaśnionej przez model
- Specyficzny dla grupy zmiennych objaśnianych
 - Biomasa drzew – jak jest mniej niż 0.90 to jest źle
 - Różnorodność runa leśnego – jak jest więcej niż 0.20 to jest mega dobrze
- Nie zawsze da się wszystko wyjaśnić
- Czy tak będzie ok? Sprawdź podobne prace

Kwadrat Ascombe'a

średnia $y=7,5$ średnia $x=9$
współczynnik $r^2=0,816$
równanie regresji:
 $y=3+0,5 \cdot x$



Czy zawsze od razu znajdziemy ładny model?

- Na pewno nie
- Dopasowanie zależy od rozkładu zmiennej – sprawdźmy
 - transformacje (log, skalowanie...)
 - inny typ modelu
 - włączenie struktur zależności (modele z efektami losowymi – po przerwie)
 - inny typ rozkładu – uogólnienie LM na inne – GLM (jutro:)

Transformacje

wielomian 2. stopnia (x^2) – `poly(x,2)`

logarytm - `log(x)`

pierwiastek - `sqrt(x)`

skalowanie i centrowanie - `scale(x)`

coś za coś – lepiej dopasowany model vs. trudniejsza interpretacja

```
ggplot(drzewa, aes(x=age, y=AB))+geom_point()+geom_smooth(method='lm')
```

Raczej krzywa niż
prosta

AB

300

200

100

0


30

60


90

120

age



Równania kwadratowe $y=ax^2+bx+c$



Wielomian drugiego stopnia
Model kwadratowy
Parabola
polynomial

model:
`lm(y~poly(x,2), data)`

```
ggplot(drzewa, aes(x=age,y=AB))+geom_point()+  
geom_smooth(method='lm',formula=y~poly(x,2))
```

Model liniowy *versus* kwadratowy


modelAB<-lm(AB~age, drzewa)

```
Call:
lm(formula = AB ~ age, data = drzewa)

Residuals:
    Min       1Q   Median       3Q      Max
-136.38  -61.14   10.26   48.10  133.88

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  74.9227    29.7421   2.519   0.0195 *
age           2.1205     0.4239   5.002 5.24e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 70.77 on 22 degrees of freedom
Multiple R-squared:  0.5322,    Adjusted R-squared:  0.5109
F-statistic: 25.02 on 1 and 22 DF, p-value: 5.237e-05
```


$$AB = 2.2105 \cdot \text{age} + 74.9277$$


modelkwadrat<-lm(AB~poly(age,2), drzewa)

```
Call:
lm(formula = AB ~ poly(age, 2), data = drzewa)


Residuals:
    Min       1Q   Median       3Q      Max
-86.027 -21.625   2.008  18.794  71.488

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  204.979      7.462  27.471 < 2e-16 ***
poly(age, 2)1  354.021     36.554   9.685 3.38e-09 ***
poly(age, 2)2 -286.568     36.554  -7.839 1.14e-07 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 36.55 on 21 degrees of freedom
Multiple R-squared:  0.8809,    Adjusted R-squared:  0.8695
F-statistic: 77.63 on 2 and 21 DF, p-value: 1.99e-10
```



$$AB = -286.6 \cdot \text{age}^2 + 354.02 \cdot \text{age} + 204.979$$

DHARMA residual




```
modelAB<-lm(AB~age, drzewa)
plot(simulateResiduals(modelAB))
```

DHARMA residual



```
modelkwadrat<-lm(AB~poly(age,2), drzewa)
plot(simulateResiduals(modelkwadrat))
```

Równania kwadratowe $y=ax^2+bx+c$



```
ggplot(drzewa, aes(x=age,y=AB))+geom_point()+  
geom_smooth(method='lm',formula=y~poly(x,2))
```


Lepsze dopasowanie
Lepsze założenia
Lepszy rozkład reszt

Biologia?

Czy w lasach gospodarczych po 90.
roku życia biomasa maleje?

I tak i nie

Może parabola nie jest najlepsza?



```
ggplot(drzewa,  
aes(x=log(age), y=log(AB)))  
+geom_point()  
+geom_smooth(method='lm')
```


Transformacja osi log

Czasem pomaga


- Tutaj nie do końca

DHARMa residual

QQ plot residuals



DHARMa residual vs. predicted
Quantile deviations detected (red curves)
Combined adjusted quantile test significant



```
Call:
lm(formula = log(AB) ~ log(age), data = drzewa)

Residuals:
    Min       1Q   Median       3Q      Max
-1.05545 -0.25316  0.09099  0.29327  0.62251

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)   0.6737     0.4604   1.463   0.158
log(age)      1.1264     0.1163   9.687 2.15e-09 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.4466 on 22 degrees of freedom
Multiple R-squared:  0.8101,    Adjusted R-squared:  0.8014
F-statistic: 93.83 on 1 and 22 DF,  p-value: 2.147e-09
```

> |

model z logarytmem

```
mod.log<-lm(log(AB)~V,data=sosny)
summary(mod.log)
```

Call:
lm(formula = log(AB) ~ V, data = sosny)

Residuals:

	Min	1Q	Median	3Q	Max
	-3.4248	-0.1294	0.1824	0.3694	0.7462

Coefficients:


	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.673302	0.109323	15.31	<2e-16 ***
V	0.029567	0.002469	11.97	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.6797 on 75 degrees of freedom

Multiple R-squared: 0.6566, Adjusted R-squared: 0.652

F-statistic: 143.4 on 1 and 75 DF, p-value: < 2.2e-16



Przykład z innego zbioru danych!

```
> mod.log<-lm(log(AB)~log(V),data=sosny)
> summary(mod.log)
```

Call:
lm(formula = log(AB) ~ log(V), data = sosny)

Residuals:


Min	1Q	Median	3Q	Max
-0.39549	-0.13620	-0.02235	0.10353	0.76807

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.59510	0.05019	11.86	<2e-16 ***
log(V)	0.74524	0.01629	45.75	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.2157 on 75 degrees of freedom
Multiple R-squared: 0.9654, Adjusted R-squared: 0.9649
F-statistic: 2093 on 1 and 75 DF, p-value: < 2.2e-16



Outliery

obserwacje odstające

wyjątki




FIGURE 7 The relationship between threatened proportion of current distribution and latitudinal center of distribution for each climate change scenario: optimistic (RCP2.6; panel a), moderate (RCP4.5; panel b), and pessimistic (RCP8.5; panel c) calculated for averaged GCMs outputs. Three species outlying from the trend—*L. decidua*, *P. menziesii*, and *Q. rubra* were removed from the regression analysis and are represented by gray dots. Gray areas around the regression lines represent standard errors (SE) of each model

Received: 20 July 2017 | Accepted: 30 August 2017
DOI: 10.1111/gcb.13925

PRIMARY RESEARCH ARTICLE

WILEY | Globa

How much does climate change threaten European forest tree species distributions?

Marcin K. Dyderski^{1,2} | Sonia Paż³ | Lee E. Frelich⁴ | Andrzej M. Jagodziński^{1,2} 

Formalna podstawa?

Outlier wynikający z błędu pomiaru

Outlier wynikający ze struktury danych (filogeneza, biologia, układ doświadczenia)

Outlier będący poprawnym pomiarem

Usunąć? Zostawić? Co jeśli Recenzent się uprze przy konieczności uzasadnienia?

Statystyki liczbowe

For inspection of outliers we checked Cook's distances and leverage values using *hat* statistics implemented in the `base::influence()` function. To identify outliers we used Bonferroni *p*-values for Studentized residuals t-tests using the `car::outlierTest()` function. After visual interpretation of diagnostic plots both for calcareous and granite grasslands we adopted 0.15 as threshold leverage values, as most of the observations had relatively low leverage values, ranging from 0.07 in calcareous and from 0.05 to 0.15 in granite grasslands. After that, we excluded two outliers: plot no. 71 (elevation 1039 m a.s.l.) from calcareous and plot no. 57 (elevation 2123 m a.s.l.) from granite grasslands due to high leverage values (0.20 and 0.24, respectively) and due to the `car::outlierTest()` $p < 0.05$ in both cases.

Źródło: Czortek et al. 2018. Cessation of livestock grazing and windthrow drive a shift in plant species composition in the Western Tatra Mts. *Tuexenia* 38: 177–196. https://www.zobodat.at/pdf/Tuexenia_NS_38_0177-0196.pdf

Rozważmy taki model

```
> model<-lm(BR~Age, data=sosny)  
> summary(model)
```

Call:
lm(formula = BR ~ Age, data = sosny)


Residuals:
Min 1Q Median 3Q Max
-6.2556 -2.2313 -1.0834 0.7993 18.5083

Coefficients:
Estimate Std. Error t value Pr(>|t|)
(Intercept) -0.08740 1.08768 -0.080 0.936
Age 0.54361 0.09568 5.681 2.41e-07 ***


Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 4.11 on 75 degrees of freedom
Multiple R-squared: 0.3009, Adjusted R-squared: 0.2916
F-statistic: 32.28 on 1 and 75 DF, p-value: 2.411e-07


Inny zbiór danych



Normal Q-Q



Residuals vs Leverage



```
as.data.frame(influence(model))
      hat coefficients..Intercept. coefficients.Age  sigma  wt.res
1 0.04155579 -3.933644e-02 2.900932e-03 4.136538 -0.706535320
2 0.04155579 -8.295232e-02 6.117460e-03 4.133604 -1.489935320
3 0.04155579 -8.381529e-02 6.181101e-03 4.133525 -1.505435320
4 0.04155579 -6.202961e-02 4.574479e-03 4.135273 -1.114135320
5 0.04155579 -6.202961e-02 4.574479e-03 4.135273 -1.114135320
6 0.03422738 -3.269323e-02 2.320786e-03 4.136651 -0.660547628
7 0.03422738 -3.136678e-02 2.226626e-03 4.136709 -0.633747628
8 0.02798310 -1.267398e-02 8.554936e-04 4.137246 -0.291659937
9 0.02798310 1.797893e-02 -1.213578e-03 4.137101 0.413740063
....
30 0.01575502 -5.745441e-02 2.754013e-03 4.129255 -2.212896862
31 0.01384724 -1.722269e-02 5.882398e-04 4.136193 -0.849509170
32 0.01384724 -3.814717e-02 1.302914e-03 4.131521 -1.881609170
33 0.01302358 2.706275e-01 -2.640268e-03 3.525303 18.508278522
34 0.01302358 3.444622e-03 -3.360607e-05 4.137297 0.235578522
35 0.01302358 1.143815e-01 -1.115917e-03 4.034866 7.822578522
36 0.01302358 2.149178e-01 -2.096759e-03 3.762979 14.698278522
37 0.01302358 -4.253562e-02 4.149817e-04 4.123362 -2.909021478
38 0.01302358 3.816302e-02 -3.723222e-04 4.126102 2.609978522
39 0.01302358 -3.526558e-02 3.440544e-04 4.127752 -2.411821478
40 0.01462865 2.132902e-02 6.081039e-03 4.069968 6.352053905
41 0.01462865 -3.423447e-03 -9.760465e-04 4.135665 -1.019546095
42 0.01462865 5.553506e-06 1.583340e-06 4.137388 0.001653905
43 0.02057022 2.738037e-02 -7.104097e-03 4.117704 -3.431870712
44 0.02516719 3.927169e-02 -7.544299e-03 4.123642 -2.862183020
45 0.02516719 -3.319243e-02 6.376441e-03 4.127573 2.419116980
46 0.02516719 -5.488588e-03 1.054387e-03 4.137120 0.400016980
```

zwraca nam wartości statystyki hat,
wartości współczynników przy odrzuceniu
obserwacji, wartość SD po odrzuceniu
obserwacji oraz ważone reszty
(wt_residuals)

można coś zobaczyć, ale nie zawsze;)

mówi o wpływie na współczynniki modelu
(coefficients)

```
library(car)
```

```
outlierTest(model)
```

	rstudent	unadjusted	p-value	Bonferonni	p
--	----------	------------	---------	------------	---

33	5.284650	1.2239e-06	0.00009424
----	----------	------------	------------

36	3.931709	1.8820e-04	0.01449200
----	----------	------------	------------

test t-studenta na istotność średniego przesunięcia od linii regresji - daje p-value surowe oraz po poprawce Bonferonniego

Wskazuje które obserwacje można roważyc jako wpływowe (ew. usunąć)

```
model<-lm(BR~Age, data=sosny)
summary(model)
```

Call:
lm(formula = BR ~ Age, data = sosny)

Residuals:

Min	1Q	Median	3Q	Max
-6.2556	-2.2313	-1.0834	0.7993	18.5083

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.08740	0.08768	-0.080	0.936
Age	0.54361	0.09568	5.681	2.41e-07 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 4.11 on 75 degrees of freedom
Multiple R-squared: 0.3009, Adjusted R-squared: 0.2916
F-statistic: 32.28 on 1 and 75 DF, p-value: 2.411e-07

```
model2<-lm(BR~Age, data=sosny[-c(33,36),])
summary(model2)
```

Call:
lm(formula = BR ~ Age, data = sosny[-c(33, 36),])

Residuals:



Min	1Q	Median	3Q	Max
-5.8548	-1.7888	-0.6365	0.8509	8.5087

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.57944	0.81816	-0.708	0.481
Age	0.54841	0.07176	7.643	6.6e-11 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.082 on 73 degrees of freedom
Multiple R-squared: 0.4445, Adjusted R-squared: 0.4369
F-statistic: 58.41 on 1 and 73 DF, p-value: 6.598e-11



Modele z większą liczbą zmiennych

proste zależności są rzadko spotykane w przyrodzie

często chcemy zbadać wpływ kilku cech

po udanym wypadzie w teren mamy aż nadto danych

czy możemy wrzucić je wszystkie na raz i zobaczyć co wyjdzie?

- Która zmienna jest kluczowa?
- Ile i które zmienne mają wpływ na to co modelujemy?
- Jak uzasadnić ich wybór i dopasowanie?

Po pierwsze – dlaczego?

- Hipotezy badawcze
 - weryfikowalne w sposób statystyczny
 - uzasadnione merytorycznie (w intro lub w MM)
- Czy mam prawo zakładać że coś ma wpływ?
 - Zależność bogactwa gatunkowego roślin od numeru powierzchni badawczej
 - Zależność liczby roślin od fazy księżyca
 - Zależność różnorodności gatunkowej grzybów od masy nasion
- Dobrze postawienie hipotezy i uzasadnienie zmiennych – połowa sukcesu

	spec	zone	plot.ID	AB	BR	total.volume	age	plot.area	basal.area	density	DBH	H
1	Picea	lowland	28	188.8861	20.7113	407.99	45	0.1056	38.31	1089.0	20.65	20.19
2	Picea	lowland	46	159.8177	21.2291	345.66	39	0.2115	31.46	595.7	25.51	21.66
3	Picea	lowland	51	270.9730	26.2697	566.35	78	0.2500	40.46	456.0	32.81	30.76
4	Picea	lowland	69	259.1293	34.0499	547.40	113	0.7400	35.23	139.2	55.30	35.66
5	Picea	lowland	71	258.1590	25.8864	598.48	66	0.2400	44.31	462.5	34.29	27.67
6	Picea	lowland	73	345.2840	33.9507	779.26	98	0.4900	49.68	271.4	47.86	35.33
	longitude	latitude										
1	15.09219	52.88818										
2	14.41213	53.66229										
3	14.49006	53.89057										
4	16.68680	54.07632										
5	16.72052	54.20158										
6	15.99423	53.69993										

Zbiór danych: drzewa (biomasa świerków)

Co może wpłynąć na biomasę (AB i BR)?

Zone – strefa lowland/highland - hipoteza że na wyżynach inaczej

N, E – koordynaty - proxy dla klimatu?

age – wiek [lata] – starsze lasy – więcej masy

density – zagęszczenie [szt. ha⁻¹] - większe zagęszczenie jest typowe dla młodszych lasów

basal.area – pole powierzchni drzew [m² ha⁻¹]

H – wysokość górna d-stanu [m]

DBH – średnia pierśnica [cm]

Total.volume – miąższość [m³ ha⁻¹] - liczone jako basal.area * H * liczba kształtu

Po drugie – jak wybrać?

- Im więcej zmiennych tym lepiej?
- Czy zmienne są zależne od siebie czy nie?
- Czy dodanie kolejnych zmiennych jest uzasadnione?

AIC - kryterium informacyjne Akaikego

miara jakości dopasowania modelu

wartości można porównywać w ramach tej samej zmiennej objaśnianej

do czego może to służyć?

porównanie jakości modeli z modelem zerowym

model zerowy - intercept-only, $Y \sim 1$, czyli wstawiamy wszędzie średnią

porównanie jakości modeli pomiędzy sobą

Czy dodanie kolejnej zmiennej jest usprawiedliwione? Zasada parsymonii

Dla modeli z jedną zmienną – porównanie jakości

```
modelzerowy<-lm(AB~1, drzewa) #bez zmiennych, średnia biomasa wszędzie  
modelAB<-lm(AB~basal.area, drzewa) #model w zależności od basal.area, ładny  
modelkwadrat<-lm(AB~poly(age,2),drzewa) #model kwadratowy z wiekiem  
AIC(modelzerowy, modelAB, modelkwadrat) #porównanie AIC
```

	df	AIC
modelzerowy	2	292.7042
modelAB	3	244.5912
modelkwadrat	4	245.6468

Oba modele lepsze niż zerowy

modelAB lepszy odrobinę niż kwadrat

W zakresie <2 jednostki AIC

Dodanie zmiennej poprawia dopasowanie modelu

```
Call:
lm(formula = AB ~ basal.area, data = drzewa)

Residuals:
    Min       1Q   Median       3Q      Max
-61.243 -26.975  -4.549   32.460   56.288

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  -19.383     19.467  -0.996   0.33
basal.area     6.435       0.516  12.471 1.89e-11 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 36.42 on 22 degrees of freedom
Multiple R-squared:  0.8761,    Adjusted R-squared:  0.8704
F-statistic: 155.5 on 1 and 22 DF,  p-value: 1.892e-11
```

```
modelAB<-lm(AB~basal.area,
drzewa)summary(modelAB)
```

```
Call:
lm(formula = AB ~ basal.area + H, data = drzewa)

Residuals:
    Min       1Q   Median       3Q      Max
-38.598 -17.841  -3.676   17.618   44.696

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  -37.0125     12.5860  -2.941  0.00781 **
basal.area     4.0244       0.5216   7.716 1.46e-07 ***
H              4.3786       0.7425   5.897 7.46e-06 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 22.88 on 21 degrees of freedom
Multiple R-squared:  0.9533,    Adjusted R-squared:  0.9489
F-statistic: 214.5 on 2 and 21 DF,  p-value: 1.057e-14
```

```
modelAB2<-lm(AB~basal.area+H,
drzewa)summary(modelAB2)
```

urościło, co z AIC?

```
> AIC(modelAB, modelAB2)
      df      AIC
modelAB  3 244.5912
modelAB2  4 223.1472
```

Dodanie wysokości polepszyło model, dodajmy więcej

```
modelAB3<-lm(AB~basal.area+H+total.volume, drzewa)
```

```
modelAB4<-lm(AB~basal.area+H+total.volume+latitude, drzewa)
```

```
AIC(modelAB, modelAB2, modelAB3, modelAB4)
```

```
> AIC(modelAB, modelAB2, modelAB3, modelAB4)
      df      AIC
modelAB  3 244.5912
modelAB2  4 223.1472
modelAB3  5 197.2125
modelAB4  6 197.3692
```

Dodanie total.volume polepszyło AIC, ale np. dodanie latitude już nie

Tylko czy to ma sens?

Współliniowość zmiennych i VIF (variance inflation factor)

Nie mówmy dwa razy o tym samym

Rule of Thumb $VIF > 5 \Rightarrow$ problem, ale...

<https://statisticalhorizons.com/multicollinearity>

<https://pdfs.semanticscholar.org/ed1f/4466a0982f3e8de202de01ecceb473d11893.pdf>

z czego wynika VIF? czy ma to biologiczne znaczenia dla badanej cechy?

library(car)

```
vif(modelAB)
```

Błąd w poleceniu 'vif.default(modelAB)':model contains fewer than 2 terms

```
vif(modelAB2)
```

basal.area	H
2.59079	2.59079

```
vif(modelAB4)
```

basal.area	H	total.volume	latitude
10.807858	5.599933	19.250710	1.122706

Dlaczego tak?

$$V=G*H*f$$

f - wskaźnik kształtu którego nie znamy

V - miąższość

G - pole powierzchni przekroju pierśnicowego

H - wysokość

cechy są ze sobą silnie związane

modelAB5<-lm(AB~basal.area+density+latitude, drzewa)

```
Call:
lm(formula = AB ~ basal.area + density + latitude, data = drzewa)

Residuals:
    Min       1Q   Median       3Q      Max
-50.764 -24.532   4.009  26.817  52.811

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -1.144e+02  2.282e+02  -0.501    0.622
basal.area   5.847e+00  6.379e-01   9.167 1.34e-08 ***
density     -5.872e-03  3.849e-03  -1.526   0.143
latitude     2.413e+00  4.263e+00   0.566   0.578
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 35.26 on 20 degrees of freedom
Multiple R-squared:  0.8944,    Adjusted R-squared:  0.8786
F-statistic: 56.46 on 3 and 20 DF,  p-value: 6.067e-10

> vif(modelAB5)
basal.area    density    latitude
  1.630526    1.710957    1.098744
```

```
> AIC(modelAB, modelAB2,
      df      AIC
modelAB      3 244.5912
modelAB2     4 223.1472
modelAB3     5 197.2125
modelAB4     6 197.3692
modelAB5     5 244.7501
```

Mamy niepokorelowane
zmienne (VIF)
Ale coś jest co powoduje
że lepszy jest model tylko
z basal.area

Szukamy dalej

Jak dobierać zmienne?

- Wg hipotez
- Nie współliniowe (VIF)
- Minimalizując AIC

W praktyce:

- Budujemy model globalny – wszystkie zmienne które mogą mieć wpływ
- Usuwamy zmienne współliniowe (w oparciu o VIF)
- Redukujemy model aby zminimalizować AIC

Budujemy model globalny

```
modelABglob<-lm(AB~total.volume+age+basal.area+density+  
DBH+H+longitude+latitude, data=drzewa) #wszystkie predyktory  
vif(modelABglob)
```

```
> vif(modelABglob)  
total.volume      age      basal.area      density      DBH      H      longitude      latitude  
19.996725      5.684332      11.670729      2.417931      22.239968      35.464456      2.492298      2.555994  
>
```

Bez sensu – wiemy że zmienne są pokorelowane. Usuńmy z nich DBH, H i basal area

```
modelABglob<-lm(AB~total.volume+age+density+longitude+latitude,  
data=drzewa)
```

```
> vif(modelABglob)  
total.volume      age      density      longitude      latitude  
2.348194      2.473863      2.335472      2.303694      1.914101  
>
```

Mamy model globalny bez zmiennych współliniowych

- Sprawdźmy wszystkie kombinacje zmiennych pod kątem AIC
- Potrzebny nam jest pakiet MuMIn
- `library(MuMIn)`
- `dredge(modelABglob)`
- Błąd w poleceniu '`dredge(modelABglob)`':
- '`global.model`'s '`na.action`' argument is not set and `options('na.action')` is "`na.omit`,"
- Dlaczego? Ochrona przed wartościami NA w danych! Trzeba zmodyfikować kod modelu dodając argument `na.action=na.fail`
- `modelABglob<-lm(AB~total.volume+age+density+longitude+latitude, data=drzewa, na.action = na.fail)`

Wynik funkcji dredge

```
> dredge(modelABglob)
Fixed term is "(Intercept)"
Global model call: lm(formula = AB ~ total.volume + age + density + longitude +
  latitude, data = drzewa, na.action = na.fail)
---
Model selection table
```

	(Int)	age	dns	lnt	lng	ttl.vlm	df	logLik	AICc	delta	weight
22	-128.700	0.2550		2.7300		0.3858	5	-92.361	198.1	0.00	0.303
18	12.120	0.2751				0.3837	4	-94.340	198.8	0.73	0.210
26	51.190	0.3021			-2.3570	0.3829	5	-93.147	199.6	1.57	0.138
21	-143.500			3.0980		0.4108	4	-95.571	201.2	3.19	0.061
30	-100.200	0.2644		2.3650	-0.5823	0.3853	6	-92.318	201.6	3.52	0.052
20	16.540	0.2566	-8.968e-04			0.3796	5	-94.133	201.6	3.54	0.051
24	-125.400	0.2519	-1.696e-04	2.6820		0.3850	6	-92.353	201.6	3.59	0.050

Zmienne i wartości współczynników dla nich

Jak nie ma wartości – kombinacja bez danej zmiennej

Liczba stopni swobody

AICc

Przyrost
AICc

Najlepiej przypisać do obiektu i otworzyć w tabeli!

modelAB.dr<-dredge(modelABglob)

klikamy

The screenshot displays the RStudio interface. On the left, the R script editor contains the following code:

```
+latitude, drzewa)  
  
modelAB4,modelAB5)  
  
e+basal.area+density+DBH+H+longitude+latitude, data=drzewa)  
  
e+density+longitude+latitude, data=drzewa)  
  
e+density+longitude+latitude, data=drzewa, na.action = na.fail)
```

On the right, the Environment pane lists the following objects:

Object	Details
klim	480 obs. of 7 variables
modelAB	List of 12
modelAB.dr	32 obs. of 11 variables
modelAB2	List of 12
modelAB3	List of 12
modelAB4	List of 12
modelAB5	List of 12
modelABage	List of 12
modelABglob	List of 12
modelkwadrat	List of 12
modelzerowy	List of 11

An orange arrow points from the word "klikamy" to a small square icon in the rightmost column of the Environment pane, specifically next to the "modelAB.dr" entry.

At the bottom right, a partial view of a scatter plot is visible, showing a positive linear trend with a blue regression line and a grey shaded confidence interval.

Otwiera się nam tabela w lepszym widoku

The screenshot displays the RStudio interface. The main editor window shows a data frame with 12 columns and 32 rows. The columns are: (Intercept), age, density, latitude, longitude, total.volum, df, logLik, AICc, delta, and weight. The data is sorted by the 'weight' column in descending order. The Environment pane on the right shows the following objects:

- klim: 480 obs. of 7 variables
- modelAB: List of 12
- modelAB.dr: 32 obs. of 11 variables
- modelAB2: List of 12
- modelAB3: List of 12
- modelAB4: List of 12
- modelAB5: List of 12
- modelABage: List of 12
- modelABglob: List of 12
- modelkwadrat: List of 12
- modelzerowy: List of 11

	(Intercept)	age	density	latitude	longitude	total.volum	df	logLik	AICc	delta	weight
22	-128.669469	0.2550469	NA	2.7304398	NA	0.3857936	5	-92.36093	198.0552	0.0000000	3.028223e-01
18	12.124955	0.2751427	NA	NA	NA	0.3836569	4	-94.34015	198.7856	0.7303753	2.101788e-01
26	51.188005	0.3020878	NA	NA	-2.3573619	0.3828959	5	-93.14662	199.6266	1.5713816	1.380279e-01
21	-143.505422	NA	NA	3.0984168	NA	0.4108001	4	-95.57105	201.2474	3.1921696	6.137862e-02
30	-100.197211	0.2643896	NA	2.3654112	-0.5823335	0.3853199	6	-92.31755	201.5763	3.5210847	5.207078e-02
20	16.536361	0.2565934	-8.968106e-04	NA	NA	0.3795588	5	-94.13258	201.5985	3.5433048	5.149547e-02
24	-125.356699	0.2518930	-1.695872e-04	2.6823726	NA	0.3849810	6	-92.35291	201.6470	3.5918151	5.026147e-02
17	16.637660	NA	NA	NA	NA	0.4106093	3	-97.54302	202.2860	4.2308624	3.651471e-02
28	51.462805	0.3041591	7.815661e-05	NA	-2.3971462	0.3832402	6	-93.14525	203.2317	5.1764866	2.275769e-02
19	25.005852	NA	-1.827214e-03	NA	NA	0.3985575	4	-96.81414	203.7336	5.6783645	1.770707e-02
23	-121.680235	NA	-1.058646e-03	2.7699522	NA	0.4037973	5	-95.31258	203.9585	5.9033149	1.582338e-02
29	-196.492279	NA	NA	3.7653801	1.1048104	0.4099608	5	-95.43743	204.2082	6.1529986	1.396630e-02
25	42.829965	NA	NA	NA	-1.5629608	0.4118547	4	-97.14213	204.3895	6.3343338	1.275572e-02
32	-100.381968	0.2637384	-2.361609e-05	2.3670006	-0.5691194	0.3852175	7	-92.31741	205.6348	7.5796412	6.843681e-03
27	38.575550	NA	-1.528839e-03	NA	-0.8912795	0.4012357	5	-96.69737	206.7281	8.6728962	3.961799e-03
31	-193.482205	NA	-1.356053e-03	3.6586492	1.6249608	0.4005956	6	-95.03634	207.0138	8.9586620	3.434307e-03
4	135.031210	1.5056716	-1.441093e-02	NA	NA	NA	4	-132.92687	275.9590	77.9038194	3.669344e-18

	(Intercept)	age	density	latitude	longitude	total.volume	df	logLik	AICc	delta	weight
22	-128.669469	0.2550469	NA	2.7304398	NA	0.3857936	5	-92.36093	198.0552	0.0000000	3.028223e-01
18	12.124955	0.2751427	NA	NA	NA	0.3836569	4	-94.34015	198.7856	0.7303753	2.101788e-01
26	51.188005	0.3020878	NA	NA	-2.3573619	0.3828959	5	-93.14662	199.6266	1.5713816	1.380279e-01
21	-143.505422	NA	NA	3.0984168	NA	0.4108001	4	-95.57105	201.2474	3.1921696	6.137862e-02
30	-100.197211	0.2643896	NA	2.3654112	-0.5823335	0.3853199	6	-92.31755	201.5763	3.5210847	5.207078e-02
20	16.536361	0.2565934	-8.968106e-04	NA	NA	0.3795588	5	-94.13258	201.5985	3.5433048	5.149547e-02
24	-125.356699	0.2518930	-1.695872e-04	2.6823726	NA	0.3849810	6	-92.35291	201.6470	3.5918151	5.026147e-02
17	16.637660	NA	NA	NA	NA	0.4106093	3	-97.54302	202.2860	4.2308624	3.651471e-02
28	51.462805	0.3041591	7.815661e-05	NA	-2.3971462	0.3832402	6	-93.14525	203.2317	5.1764866	2.275769e-02
19	25.005852	NA	-1.827214e-03	NA	NA	0.3985575	4	-96.81414	203.7336	5.6783645	1.770707e-02
23	-121.680235	NA	-1.058646e-03	2.7699522	NA	0.4037973	5	-95.31258	203.9585	5.9033149	1.582338e-02
29	-196.492279	NA	NA	3.7653801	1.1048104	0.4099608	5	-95.43743	204.2082	6.1529986	1.396630e-02
25	42.829965	NA	NA	NA	-1.5629608	0.4118547	4	-97.14213	204.3895	6.3343338	1.275572e-02
32	-100.381968	0.2637384	-2.361609e-05	2.3670006	-0.5691194	0.3852175	7	-92.31741	205.6348	7.5796412	6.843681e-03
27	38.575550	NA	-1.538830e-03	NA	-0.8012705	0.4012357	5	-96.60737	206.7381	8.6738052	3.061700e-03

- Najlepiej dopasowany model ma age, latitude oraz total.volume
- AICc modelu to 198.055
- Model zerowy to model z najmniejszą df (kliknij na df by posortować)

	(Intercept)	age	density	latitude	longitude	total.volume	df	logLik	AICc	delta	weight
1	204.978833	NA	NA	NA	NA	NA	2	-144.35212	293.2757	95.2204808	6.372696e-22
17	16.637660	NA	NA	NA	NA	0.4106093	3	-97.54302	202.2860	4.2308624	3.651471e-02
2	74.922708	2.1204803	NA	NA	NA	NA	3	-135.23655	277.6731	79.6179037	1.557327e-18
3	246.756854	NA	-2.687741e-02	NA	NA	NA	3	-137.38275	281.9655	83.9103181	1.820933e-19
9	113.304385	NA	NA	NA	5.3536782	NA	3	-144.25691	295.7138	97.6586241	1.883160e-22
5	68.703509	NA	NA	2.6380697	NA	NA	3	-144.32542	295.8508	97.7956616	1.758449e-22
18	12.124955	0.2751427	NA	NA	NA	0.3836569	4	-94.34015	198.7856	0.7303753	2.101788e-01

- AICc modelu zerowego to 293.2757 (model tylko z interceptem)
- Dlaczego AICc a nie AIC – domyślnie liczy AIC corrected for small sample size
- Można zadać mu AIC w funkcji dredge
- `dredge(modelABglob, rank=„AIC”)`

Trochę inne wyniki

```
> dredge(modelABglob, rank = 'AIC')
Fixed term is "(Intercept)"
Global model call: lm(formula = AB ~ total.volume + age + density + longitude +
  latitude, data = drzewa, na.action = na.fail)
---
```

Model selection table

	(Int)	age	dns	ltt	lng	ttl.vlm	df	logLik	AIC	delta	weight
22	-128.700	0.2550		2.7300		0.3858	5	-92.361	194.7	0.00	0.293
26	51.190	0.3021			-2.3570	0.3829	5	-93.147	196.3	1.57	0.134
30	-100.200	0.2644		2.3650	-0.5823	0.3853	6	-92.318	196.6	1.91	0.113
18	12.120	0.2751				0.3837	4	-94.340	196.7	1.96	0.110
24	-125.400	0.2519	-1.696e-04	2.6820		0.3850	6	-92.353	196.7	1.98	0.109
20	16.540	0.2566	-8.968e-04			0.3796	5	-94.133	198.3	3.54	0.050

- Przy $n/K < 40$ lepiej stosować AICc niż AIC (pomoc do funkcji ?AICc)
- N – liczba obserwacji, K – liczba predyktorów
- Zwykle mamy małe bazy

Model finalny

```
Call:
lm(formula = AB ~ total.volume + age + latitude, data = drzewa)
```

Residuals:

Min	1Q	Median	3Q	Max
-20.3940	-7.9735	0.4135	4.5856	26.5984

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-128.66947	74.56829	-1.726	0.0999 .
total.volume	0.38579	0.01466	26.314	<2e-16 ***
age	0.25505	0.10298	2.477	0.0223 *
latitude	2.73044	1.44181	1.894	0.0728 .

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 12.44 on 20 degrees of freedom
Multiple R-squared: 0.9869, Adjusted R-squared: 0.9849
F-statistic: 500.9 on 3 and 20 DF, p-value: < 2.2e-16

Główny wpływ –
volume oraz age

Latitude – nieistotny
statystycznie ale
nadal ulepsza model

zostaje

To nie jest magiczne narzędzie

- Czy zawsze należy używać dredge()? Zależy do celu:
 - Przetestowanie hipotez – nie, skupiamy się na predyktorach wybranych na podstawie stanu wiedzy, albo mamy efekt albo nie mamy
 - Szukanie głównych determinantów – tak, jest to sposób na wybór optymalnego modelu
- Czy dredge() zawsze da najlepszy model? Nie, bo nie chroni przed:
 - Współliniowością (trzeba sprawdzić VIFy)
 - Brakiem logiki (dobór predyktorów)
 - Ukrytymi interakcjami






Średnie brzegowe/ odpowiedzi brzegowe

- Model z więcej niż jedną zmienną trudniej pokazać
- Jak zmienia się wartość oczekiwana przy założeniu że pozostałe parametry są stałe?
- $\text{Masa} = 2.5 * \text{wysokość} + \text{typ1} * 0.2 + \text{typ2} * 0.5 + \text{typ3} * (-0.3)$
- Wiemy jak typ modyfikuje masę przy danej wysokości, ale jak pokazać średnie wartości z modelu?
- Co jak jest więcej zmiennych?

marginal means, emmeans, marginal response, partial dependence

Summary jedno, obrazki drugie



Dlaczego?

Każdy obrazek osobno, bez całościowego uwzględnienia modelu

Jak to się liczy?

```
Call:
lm(formula = AB ~ total.volume + age + latitude, data = drzewa)

Residuals:
    Min       1Q   Median       3Q      Max
-20.3940  -7.9735   0.4135   4.5856  26.5984

Coefficients:
            AB=2.73*latitude+0.255*age+0.3857*volume-128.67
(Intercept) -128.66947    Std. Error 74.56829    t value -1.726    Pr(>|t|) 0.0999 .
total.volume  0.38579    Std. Error  0.01466    t value 26.314    <2e-16 ***
age           0.25505    Std. Error  0.10298    t value  2.477    0.0223 *
latitude     2.73044    Std. Error  1.44181    t value  1.894    0.0728 .
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 12.44 on 20 degrees of freedom
Multiple R-squared:  0.9869,    Adjusted R-squared:  0.9849
F-statistic: 500.9 on 3 and 20 DF,  p-value: < 2.2e-16
```

- Podstawiamy stałą wartość pod age i latitude oraz wszystkie wartości pod volume

Marginal response

- Odpowiedź brzegowa, zakładająca średni poziom pozostałych zmiennych
- $y = ax_1 + bx_2 + cx_3 + d$, podstawiamy pod x_1 poszczególne wartości
- pod x_2 i pod x_3 podstawiamy średnią wartość z zestawu danych
- mamy więc obraz jak wraz ze zmianą x_1 zmieni się y przy założeniu że pozostałe czynniki się nie zmieniają
- *ceteris paribus* – wszystkie bez jednego się nie zmieniają
- `library(ggeffects)`

ggpredict(modelABglob)

\$total.volume

Predicted values of AB

total.volume | Predicted | 95% CI

0	28.45	13.22, 43.67
110	70.88	58.75, 83.01
210	109.46	99.99, 118.94
320	151.90	144.95, 158.85
430	194.34	188.92, 199.76
540	236.77	231.02, 242.53
650	279.21	271.50, 286.93
860	360.23	347.08, 373.37

Adjusted for:

* age = 63.00

* latitude = 51.66

**Jaka będzie biomasa przy
V=110 zakładając 63-letni
las na lat=51.6?**

\$age

Predicted values of AB

age | Predicted | 95% CI

7	191.12	178.31, 203.94
21	194.69	184.54, 204.85
34	198.01	190.10, 205.91
48	201.58	195.56, 207.60
62	205.15	199.85, 210.45
76	208.72	202.56, 214.88
90	212.29	204.17, 220.41
117	219.18	206.10, 232.25

Adjusted for:

* total.volume = 458.69

* latitude = 51.66

**O ile zmieni się biomasa
drzewostanu o tej samej V
i latitude między 34 a 62
rokiem życia?**

\$latitude

Predicted values of AB

latitude | Predicted | 95% CI




49.00	198.15	188.52, 207.77
49.50	199.51	191.10, 207.92
50.50	202.24	195.88, 208.61
51.00	203.61	197.93, 209.29
51.50	204.97	199.64, 210.31
52.50	207.71	201.84, 213.57
53.00	209.07	202.42, 215.72
54.50	213.17	203.13, 223.20

Adjusted for:

* total.volume = 458.69




* age = 63.00

plot(ggpredict(modelABglob)), trzy osobne wykresy



fajnie ale nie widać efektów – różne skale osi

```
plot(ggpredict(modelABglob),show_data = T)
```




- Dodaje punkty z rzeczywistymi danymi
- Nadal brzydko

Można wywoływać je osobno

Predicted values of AB


```
plot(ggpredict(modelABglob, 'total.volume'), show_data = T)
```




Przypisać do obiektów i pokazać razem

```
library(gridExtra)
plot1<-plot(ggpredict(modelABglob, 'total.volume'),show_data = T)
plot2<-plot(ggpredict(modelABglob, 'latitude'),show_data = T)
plot3<-plot(ggpredict(modelABglob, 'age'),show_data = T)
grid.arrange(plot1,plot2,plot3, nrow=1)
```


Predicted values of AB



Predicted values of AB



Predicted values of AB



Średnie brzegowe – marginal means – średnie z modelu

```
modelpiwo<-lm(IBU~BLG+typ,piwo)
summary(modelpiwo)
```

```
Call:
lm(formula = IBU ~ BLG + typ, data = piwo)

Residuals:
    Min       1Q   Median       3Q      Max
-32.35  -5.97  -0.97   4.21  49.49

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  -6.4977    5.1253  -1.268  0.20747
BLG           3.2615    0.3149   10.358 < 2e-16 ***
typinne     -10.0393    4.6334  -2.167  0.03234 *
typlager    -11.1436    5.1188  -2.177  0.03154 *
typpale ale  15.0354    3.7160   4.046 9.51e-05 ***
typPils       9.8233    5.1179   1.919  0.05743 .
typPorter     5.0366    5.2992   0.950  0.34390
typRIS       15.4208    6.9832   2.208  0.02923 *
typSour     -10.9477    4.9513  -2.211  0.02903 *
typStout     -6.4548    4.8237  -1.338  0.18351
typwheat    -15.0796    4.4519  -3.387  0.00097 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 11.35 on 114 degrees of freedom
Multiple R-squared:  0.7578,    Adjusted R-squared:  0.7365
F-statistic: 35.66 on 10 and 114 DF,  p-value: < 2.2e-16
```

emmeans(modelpiwo, 'typ')

typ	emmean	SE	df	lower.CL	upper.CL
eurolager	42.7	3.22	114	36.3	49.0
inne	32.6	3.20	114	26.3	39.0
Lager	31.5	4.02	114	23.5	39.5
pale ale	57.7	1.87	114	54.0	61.4
Pils	52.5	4.17	114	44.2	60.7
Porter	47.7	3.99	114	39.8	55.6
RIS	58.1	5.85	114	46.5	69.7
Sour	31.7	3.79	114	24.2	39.2
Stout	36.2	3.59	114	29.1	43.3
Wheat	27.6	3.24	114	21.2	34.0

emmean – średnia wartość IBU dla typu,
zakładając że BLG jest na tym samym poziomie

cld(emmeans(modelpiwo, 'typ'))

typ	emmean	SE	df	lower.CL	upper.CL	.group
Wheat	27.6	3.24	114	21.2	34.0	1
Lager	31.5	4.02	114	23.5	39.5	12
Sour	31.7	3.79	114	24.2	39.2	12
inne	32.6	3.20	114	26.3	39.0	12
Stout	36.2	3.59	114	29.1	43.3	123
eurolager	42.7	3.22	114	36.3	49.0	23
Porter	47.7	3.99	114	39.8	55.6	234
Pils	52.5	4.17	114	44.2	60.7	34
pale ale	57.7	1.87	114	54.0	61.4	4
RIS	58.1	5.85	114	46.5	69.7	34

Wrzucenie emmeans() w funkcję cld() daje nam porównanie testem Tukeya

mamy zaznaczone grupy które na $p=0.05$ się nie różnią

Np. Wheat nie różni się od Lager i Stout (wszystkie mają numer 1)

eurolager różni się od Wheat, ale nie od Lager

Confidence level used: 0.95

P value adjustment: tukey method for comparing a family of 10 estimates

significance level used: $\alpha = 0.05$

NOTE: If two or more means share the same grouping symbol,


then we cannot show them to be different.

But we also did not show them to be the same.

emmans można łatwo pokazać w postaci obrazka


```
ggplot(df.emmeans, aes(x=typ, y=emmean))  
+geom_col()
```

Wersja basic




```
ggplot(df.emmeans, aes(x=typ, y=emmean))  
+geom_errorbar(aes(ymin=emmean-SE,  
ymax=emmean+SE)) +geom_col()
```

Dodajmy errorbary




```
ggplot(df.emmeans, aes(x=typ, y=emmean))  
+geom_errorbar(aes(ymin=emmean-  
SE,ymax=emmean+SE)) +geom_col()  
+geom_text(aes(label=.group))
```

Brzydkie cyfry, można je
przesunąć wyżej



```
ggplot(df.emmeans, aes(x=typ,  
y=emmean))  
+geom_errorbar(aes(ymin=emmean-  
SE,ymax=emmean+SE)) +geom_col()  
+geom_text(aes(label=.group,  
y=1.1*(emmean+SE)))
```


Zadajemy że cyferki
powinny być na wysokości
120% sumy emmean i SE



Zamiana cyfr na litery wg konwencji z publikacji

```
df.emmeans$.group<-gsub(1,'a',df.emmeans$.group)
df.emmeans$.group<-gsub(2,'b',df.emmeans$.group)
df.emmeans$.group<-gsub(3,'c',df.emmeans$.group)
df.emmeans$.group<-gsub(4,'d',df.emmeans$.group)
df.emmeans$.group<-gsub(' ','',df.emmeans$.group)
```

Funkcja `gsub(pattern, replace, where)` – zamień `pattern` na `replace` w obiekcie `where`



Marginal mean (+SE) IBU in beer styles, predicted from linear model (Table X), assuming constant (mean) level of all other predictors. Groups denoted by the same letter did not differ at $p=0.05$ according to Tukey's posteriori tests

Przykład: wpływ inwazyjnych drzew na mszaki

- dataset – pokrycie mszaków epigeicznych w Wielkopolskim PN
- budujemy model globalny

```
bssmodel<-lm(Cover.moss.layer....~soilpH+soilCN+DIFN+type,  
data=plots,na.action=na.fail)
```

```
car::vif(bssmodel)
```

GVIF Df GVIF^(1/(2*Df))

soilpH 2.069323 1 1.438514

soilCN 2.015716 1 1.419759

DIFN 1.527215 1 1.235805

type 3.500151 8 1.081447

Folia Geobot (2020) 55:351–363
<https://doi.org/10.1007/s12224-020-09384-2>

**Impacts of alien tree species on the abundance and diversity
of terricolous bryophytes**

Marcin K. Dyderski  • Andrzej M. Jagodziński 



```
> dredge(bssmodel)
```

Fixed term is "(Intercept)"

Global model call: `lm(formula = Cover.moss.layer.... ~ soilpH + soilCN + DIFN + type, data = plots, na.action = na.fail)`

```
Model selection table
  (Intrc)  DIFN      soilCN      soilpH type df  logLik   AICc   delta weight
12  0.016380 3.503 -0.0039580          + 12 127.928 -230.1    0.00  0.399
10 -0.078880 3.435          + 11 126.618 -229.7    0.33  0.338
16  0.061090 3.515 -0.0042590 -9.279e-03 + 13 128.114 -228.1    1.94  0.151
14 -0.062430 3.438          -4.076e-03 + 12 126.655 -227.5    2.55  0.112
 2 -0.075550 4.121          3 96.136 -186.1   43.91  0.000
 4 -0.055590 4.170 -0.0009355          4 96.222 -184.2   45.83  0.000
 6 -0.075120 4.121          -9.312e-05 4 96.137 -184.1   46.00  0.000
 8 -0.029210 4.173 -0.0013070 -4.000e-03 5 96.257 -182.2   47.87  0.000
 9  0.004750          + 10 73.461 -125.7  104.39  0.000
13 -0.006928          2.880e-03 + 11 73.472 -123.4  106.63  0.000
11 -0.003788      0.0003487 + 11 73.467 -123.4  106.64  0.000
15 -0.020230      0.0004542 3.418e-03 + 12 73.481 -121.2  108.89  0.000
 3 -0.166600      0.0114000 3 30.367 -54.6  175.45  0.000
 7 -0.184100      0.0116400 2.651e-03 4 30.374 -52.5  177.53  0.000
 5  0.263000      -3.622e-02 3 25.133 -44.1  185.92  0.000
 1  0.102600          2 23.221 -42.4  187.68  0.000
Models ranked by AICc(x)
> |
```

Model finalny: DIFN, soilC:N oraz type

```
lm(formula = Cover.moss.layer.... ~ soilCN + DIFN + type, data = plots,  
na.action = na.fail)
```

Residuals:

Min	1Q	Median	3Q	Max
-0.38648	-0.04396	0.00196	0.03929	0.52344

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	0.016382	0.072649	0.225	0.82186	
soilCN	-0.003958	0.002512	-1.576	0.11685	
DIFN	3.502543	0.296747	11.803	< 2e-16	***
typePinus plantation	0.007056	0.043492	0.162	0.87131	
typePinus plantation - Ps	0.091420	0.048747	1.875	0.06240	.
typePinus poor	0.243618	0.061564	3.957	0.00011	***
typePinus poor - Ps	0.152591	0.049856	3.061	0.00256	**
typeQ. petraea	-0.081435	0.047951	-1.698	0.09123	.
typeQ. rubra	-0.041634	0.053871	-0.773	0.44065	
typeQuercus-Acer-Tilia	-0.012353	0.050637	-0.244	0.80755	
typeRobinia	-0.005330	0.059131	-0.090	0.92829	

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.1254 on 175 degrees of freedom

Multiple R-squared: 0.6756, Adjusted R-squared: 0.6571




F-statistic: 36.45 on 10 and 175 DF, p-value: < 2.2e-16

No fajnie, ale co z tego?



Wyszukaj






```
plot1<-plot(ggpredict(bssmodel2, 'DIFN'))  
plot2<-plot(ggpredict(bssmodel2, 'soilCN'))  
plot3<-plot(ggpredict(bssmodel2, 'type'))  
grid.arrange(plot1,plot2,plot3, nrow=1)
```

Lepiej pokazać zmienną kategoriyczną emmenas

```
df.mm<-as.data.frame(cld(emmeans(bssmodel2, 'type')))  
ggplot(df.mm, aes(x=type, y=emmean))+  
geom_errorbar(aes(ymin=emmean-SE,  
ymax=emmean+SE)) +geom_col()  
+geom_text(aes(label=.group, y=1.1*(emmean+SE)))  
+coord_flip()
```



Model z interakcją

znaki w formule: + addytywność (wspólne oddziaływanie)

: interakcja *addytywność i interakcja

```
> an2<-aov(lm(AB~type:Soil.type,data=sosny))
> summary(an2)
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
type:Soil.type	10	7125	712.5	2.673	0.0083 **
Residuals	66	17590	266.5		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```
> an2<-aov(lm(AB~type*Soil.type,data=sosny))
> summary(an2)
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
type	2	3767	1883.4	7.067	0.00166 **
Soil.type	7	3326	475.1	1.783	0.10554
type:Soil.type	1	32	32.2	0.121	0.72917
Residuals	66	17590	266.5		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Co znaczy interakcja?

Różne różnice pomiędzy grupami jednego czynnika w grupach drugiego czynnika

np. gatunki iglaste w ramach jednej grupy będą miały większy przyrost biomasy niż w ramach drugiej grupy

Czy sprawdzać wszystkie możliwe interakcje (full-factorial)?

Nie, bo testujemy coś dla czego nie ma uzasadnienia?

Tak, bo może za kilkanaście lat ktoś będzie miał uzasadnienie?

Tylko te które możemy uzasadnić biologicznie (hipotezy)?

Przykład – zagęszczenie czeremchy amerykańskiej




Fig. 1. Spatial distribution of natural black cherry regeneration density (all height classes) in Rogów Arboretum.



Plantation of coniferous trees modifies risk and size of *Padus serotina* (Ehrh.) Borkh. invasion – Evidence from a Rogów Arboretum case study

Andrzej M. Jagodziński^{a,b,*}, Marcin K. Dyderski^c, Mateusz Rawlik^d, Piotr Banaszczyk^e

	df	AIC
mconi	7	934.0510
mcon1	5	953.7521
mcon2	5	960.6979

$\log_{1p}(x)$ to $\log(x+1)$

pase – zagęszczenie czeremchy

odl – odległość od źródła nasion

igl – typ d-stanu (3 poziomy)

```
mconi<-lm(log1p(pase)~log(odl)*igl,data=dane)
mcon1<-lm(log1p(pase)~log(odl)+igl,data=dane)
mcon2<-lm(log1p(pase)~log(odl):igl,data=dane)
AIC(mconi,mcon1,mcon2)
```

Call:

lm(formula = log1p(pase) ~ log(odl) * igl, data = dane)

Residuals:

Min	1Q	Median	3Q	Max
-7.9034	-1.3385	-0.8346	1.4789	6.6448

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	19.0511	1.8077	10.539	< 2e-16 ***
log(odl)	-2.9116	0.3306	-8.806	7.03e-16 ***
iglLIS	-15.5681	3.5483	-4.387	1.88e-05 ***
iglMIX	-15.9376	3.4419	-4.630	6.65e-06 ***
log(odl):iglLIS	2.5064	0.6543	3.831	0.000172 ***
log(odl):iglMIX	2.5157	0.6241	4.031	7.96e-05 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.423 on 195 degrees of freedom

Multiple R-squared: 0.3771, Adjusted R-squared: 0.3611



F-statistic: 23.61 on 5 and 195 DF, p-value: < 2.2e-16

Co wynika z tabelki?

Na zagęszczenie czeremchy wpływa:
typ drzewostanu (igl) – w LIS i MIX mniej niż w iglastych (referencja)
odległość od źródła nasion – negatywnie


i interakcja – za coraz większą odległość na LIS i MIX są punkty dodatnie – łagodzące negatywny efekt odległości i d-stanu

Tylko zależność addytywna – bez interakcji



```
ggpredict(mconif, c('odl','igl'))%>%plot()+scale_y_log10()
```

Z interakcją



Modele liniowe z efektami losowymi i stałymi (LMM)

a.k.a. modele mieszane, modele z efektem losowym, powtarzalne pomiary,

linear mixed-effect models/ generalized linear mixed-effects model,

Po co nam modele?

- przybliżenie procesu
- estymacja – szacowanie wartości oczekiwanej
- uwzględnianie dodatkowych czynników – co by było gdyby?
- zgodność z założeniami – niezależność obserwacji

efekt stały a efekt losowy

stały - związany z działaniem czynnika

losowy - związany z elementami które powinny być niezależne, a mogą mieć wpływ, np. wariant doświadczenia, powtórzenie, termin, itp.

Przykład

3 terminy badań na **6** blokach po **10** poletek **4** gatunków drzew - światło i odczyn

światło, odczyn, gatunek drzewa - efekty stałe

termin badań, poletko, blok - efekty losowe

Po co efekty losowe

niezależność obserwacji - możliwość wnioskowania i ekstrapolacji

zależność czasowa, przestrzenna, filogenetyczna, osobnicza...

uwypuklenie trendu z uwzględnieniem kontekstu

ocena zmienności na różnych poziomach hierarchii

“a co jeśli jakieś poletko jest odwiedzane przez psy i koty - to też może mieć wpływ na zbiorowiska mszaków epifitycznych przez dopływ biogenów i wydrapywanie?” - plot-specific effects

Przykłady

- przestrzenna: po 4 poletka na 10 transektach – nr transektu jako RE
- czasowa: 20 niezależnych poletek w 3 terminach – termin jako RE
- filogenetyczna: 100 gatunków z 40 rodzin – gatunek:rodzina jako RE
- osobnicza: kleszcze z 20 saren, pięć części ciała na sarnę – ID sarny jako RE

Buki – modele biomasy drzew

- `buki<-read.csv('buki.csv',sep=';')`
- `head(buki)`

```
plot.ID position      AB      H      DBH
1      104        1 1413.7366 31.79 43.10
2      104        2 1108.2655 32.95 37.65
3      104        3  986.9901 34.63 33.60
4      104        4  657.8840 29.95 29.35
5      104        5  550.6060 31.58 27.10
6      104        6  384.6096 28.68 24.20
> |
```

Osiem drzew modelowych na plot

Zależność w ramach poletka:

Historia gospodarki

Warunki klimatyczne

Konkurencja

```
lm(formula = AB ~ DBH, data = buki)
```

Residuals:

Min	1Q	Median	3Q	Max
-571.6	-287.0	-100.7	234.2	2193.7

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-558.92	51.91	-10.77	<2e-16 ***
DBH	53.17	1.75	30.38	<2e-16 ***


Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 384.5 on 190 degrees of freedom

Multiple R-squared: 0.8293, Adjusted R-squared: 0.8284

F-statistic: 923 on 1 and 190 DF, p-value: < 2.2e-16

```
buk.lm<-lm(AB~DBH, buki)
summary(buk.lm)
ggplot(buki, aes(x=DBH,y=AB))
+geom_point()
+geom_smooth(method='lm')
```




```
Residuals:
    Min       1Q   Median       3Q      Max
-0.61224 -0.13486  0.01447  0.12346  1.03175

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -2.53803    0.04605  -55.12  <2e-16 ***
log(DBH)      2.66115    0.01511  176.12  <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1


Residual standard error: 0.2057 on 190 degrees of freedom
Multiple R-squared:  0.9939,    Adjusted R-squared:  0.9939
F-statistic: 3.102e+04 on 1 and 190 DF,  p-value: < 2.2e-16
```

log(AB)



```
buk.lm<-lm(log(AB)~log(DBH), buki)
summary(buk.lm)
ggplot(buki,
aes(x=log(DBH),y=log(AB)))
+geom_point()
+geom_smooth(method='lm')
```

```
ggplot(buki, aes(x=log(DBH),y=log(AB),col=factor(plot.ID)))  
+geom_point()+geom_smooth(method='lm')
```



```
buk.lm<-lm(log(AB)~log(DBH), buki)
```

- Model liniowy

```
library(lmerTest)
```

```
buk.lmm<-lmer(log(AB)~log(DBH)  
+(1|plot.ID), buki)
```

- Model liniowy z efektem stałym (DBH) i losowym (plot.ID)

```
Residuals:  
      Min       1Q   Median       3Q      Max   
-0.61224 -0.13486  0.01447  0.12346  1.03175   
  
Coefficients:  
            Estimate Std. Error t value Pr(>|t|)      
(Intercept) -2.53803    0.04605  -55.12   <2e-16 ***  
log(DBH)      2.66115    0.01511  176.12   <2e-16 ***  
---  
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1  
  
Residual standard error: 0.2057 on 190 degrees of freedom  
Multiple R-squared:  0.9939,    Adjusted R-squared:  0.9939  
F-statistic: 3.102e+04 on 1 and 190 DF,  p-value: < 2.2e-16
```

```
Linear mixed model fit by REML. t-tests use Satterthwaite's method ['lmerModLmer']  
Formula: log(AB) ~ log(DBH) + (1 | plot.ID)  
Data: buki
```

```
REML criterion at convergence: -137.1
```

```
Scaled residuals:  
      Min       1Q   Median       3Q      Max   
-3.3154 -0.4372  0.0478  0.4927  5.2507
```

```
Random effects:  
Groups   Name      Variance Std.Dev.  
plot.ID (Intercept) 0.10560  0.3250  
Residual              0.01694  0.1302  
Number of obs: 192, groups: plot.ID, 24
```

```
Fixed effects:  
            Estimate Std. Error      df t value Pr(>|t|)      
(Intercept) -1.73220    0.11118  65.49752  -15.58   <2e-16 ***  
log(DBH)      2.38181    0.03076 178.29333   77.44   <2e-16 ***  
---  
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Correlation of Fixed Effects:  
      (Intr)  
log(DBH) -0.798
```

```
buk.lm<-lm(log(AB)~log(DBH), buki)
```

```
library(lmerTest)
```

```
buk.lmm<-lmer(log(AB)~log(DBH)  
+(1|plot.ID), buki)
```

```
Residuals:  
      Min       1Q   Median       3Q      Max   
-0.61224 -0.13486  0.01447  0.12346  1.03175  
  
Coefficients:  
            Estimate Std. Error t value Pr(>|t|)      
(Intercept) -2.53803    0.04605  -55.12  <2e-16 ***  
log(DBH)      2.66115    0.01511   176.12  <2e-16 ***  
---  
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1  
  
Residual standard error: 0.2057 on 190 degrees of freedom  
Multiple R-squared:  0.9939,    Adjusted R-squared:  0.9939  
F-statistic: 3.102e+04 on 1 and 190 DF,  p-value: < 2.2e-16
```

$\log(AB) = -2.538 + 2.66 \cdot \log(DBH)$

```
Linear mixed model fit by REML. t-tests use Satterthwaite's method ['lmerModLmerTest']  
Formula: log(AB) ~ log(DBH) + (1 | plot.ID)  
Data: buki  
  
REML criterion at convergence: -137.1  
  
Scaled residuals:  
      Min       1Q   Median       3Q      Max   
-3.3154 -0.4372  0.0478  0.4927  5.2507  
  
Random effects:  
Groups   Name             Variance Std.Dev.  
plot.ID  (Intercept)  0.10560  0.3250  
Residual                0.01694  0.1302  
Number of obs: 192, groups: plot.ID, 24  
  
Fixed effects:  
            Estimate Std. Error    df t value Pr(>|t|)      
(Intercept) -1.73220    0.11118  65.49752  -15.58  <2e-16 ***  
log(DBH)      2.38181    0.03076 178.29333   77.44  <2e-16 ***  
---  
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1  
  
Correlation of Fixed Effects:  
      (Intr)  
log(DBH) -0.798
```

$\log(AB) = -1.732 + 2.38 \cdot \log(DBH) + u_i$

u_i – modyfikator specyficzny dla poletka, $sd(u_i) = 0.325$

Co to są te u?

- Dla każdego poletka specyficzny modyfikator przesuwający położenie linii regresji
- Ich suma jest bliska zeru
- W modelu mamy uwzględnione zróżnicowanie między poletkami (efekty losowe)
- Efekt stały – trend dla globalnej populacji
- Ważne dla transferu wniosków
- Model uwzględniający strukturę zależności jako random effects daje oszacowania niezależne od lokalnych uwarunkowań
- Można użyć tych modeli poza układem badań

- Można zobaczyć
- `ranef(buk.lmm)`

```
$plot.ID  
(Intercept)  
4      0.09080152  
17     -0.53122166  
18      0.06914459  
27     -0.41847647  
35      0.23226252  
37      0.07088193  
41      0.30686267  
65      0.30206463  
70      0.15642507  
91     -0.60635225  
93      0.10934917  
96      0.04607188  
100     0.18445522  
104     0.13667551  
108     0.19163812  
111    -0.23591577  
116     0.26370210  
119     0.28502719  
129    -0.92958285  
130    -0.11092430  
131     0.08997578  
132     0.22828008  
144    -0.01989154  
170     0.08874688
```

Ile procent wyjaśnia?

więcej o metodzie i praca do cytowania r2c/r2m
<https://doi.org/10.1111/j.2041-210x.2012.00261.x>

```
> library(MuMIn)
> r.squaredGLMM(buk.lmm)
      R2m      R2c
[1,] 0.9782146 0.9969881
```

R2m - marginal R2; R2c - conditional R2

R2m - % zmienności wyjaśnionej przez fixed effects

R2c - % zmienności wyjaśnionej przez fixed + random effects

random effects - R2c-R2m

Zależność w ramach browaru

```
modelpiwo<-lm(IBU~BLG+typ,piwo)
summary(modelpiwo)
```

```
modelpiwolmm<-lmer(IBU~BLG+typ+(1|browar),piwo)
summary(modelpiwolmm)
```

```
Call:
lm(formula = IBU ~ BLG + typ, data = piwo)

Residuals:
    Min       1Q   Median       3Q      Max
-32.35  -5.97  -0.97   4.21  49.49

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  -6.4977     5.1253  -1.268  0.20747
BLG           3.2615     0.3149  10.358 < 2e-16 ***
typinne     -10.0393     4.6334  -2.167  0.03234 *
typLager    -11.1436     5.1188  -2.177  0.03154 *
typpale ale  15.0354     3.7160   4.046 9.51e-05 ***
typPils       9.8233     5.1179   1.919  0.05743 .
typPorter     5.0366     5.2992   0.950  0.34390
typRIS       15.4208     6.9832   2.208  0.02923 *
typSour     -10.9477     4.9513  -2.211  0.02903 *
typStout     -6.4548     4.8237  -1.338  0.18351
typwheat    -15.0796     4.4519  -3.387  0.00097 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 11.35 on 114 degrees of freedom
Multiple R-squared:  0.7578,    Adjusted R-squared:  0.7365
F-statistic: 35.66 on 10 and 114 DF,  p-value: < 2.2e-16
```

```
Random effects:
 Groups      Name      Variance Std.Dev.
browar      (Intercept) 14.88    3.857
Residual    114.39    10.696
Number of obs: 125, groups: browar, 18

Fixed effects:
            Estimate Std. Error      df t value Pr(>|t|)
(Intercept)  -4.3401     5.3893  84.8462  -0.805  0.42288
BLG           3.1138     0.3093 113.0861  10.067 < 2e-16 ***
typinne     -9.7628     5.0152  63.9316  -1.947  0.05597 .
typLager    -10.1856     5.5000  71.1598  -1.852  0.06818 .
typpale ale  14.7831     4.2454  42.2342   3.482  0.00117 **
typPils       8.0062     5.3249  90.2239   1.504  0.13619
typPorter     4.6738     5.5879  79.2132   0.836  0.40543
typRIS       16.8959     7.2688  93.6829   2.324  0.02226 *
typSour     -12.1794     5.3004  71.4113  -2.298  0.02450 *
typStout     -7.1459     5.1959  68.8106  -1.375  0.17350
typwheat    -14.8500     4.8775  59.1047  -3.045  0.00348 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
r.squaredGLMM(modelpiwolmm)
```

```
      R2m      R2c
[1,] 0.7331897 0.7638956
```

Browar wyjaśnia 3% zmienności

Przykład: wpływ obcych gatunków drzew na biodiv

- 9 typów lasu, schemat blokowy
- spisy florystyczne, miary różnorodności o rozkładzie ~normalnym
- Hipoteza: różnice między typami lasów
- Efekt stały: typ lasu, efekt losowy: blok (random intercept)

- Model globalny:

```
mo.shan<-lmer(shan~type+(1|Blok),data=div,na.action = na.fail)
```

```
dredge(mo.shan)
```

Model selection table

	(Intrc)	type	df	logLik	AICc	delta	weight
2	1.950	+	11	-118.811	261.1	0.00	0.96
1	2.563		3	-130.688	267.5	6.37	0.04

Biol Invasions (2021) 23:235–252
<https://doi.org/10.1007/s10530-020-02367-6>

ORIGINAL PAPER



Impacts of invasive trees on alpha and beta diversity of temperate forest understories

Marcin K. Dyderski · Andrzej M. Jagodziński

summary(mo.shan)

Formula: shan ~ type + (1 | Blok)
Data: div

REML criterion at convergence: 237.6

Scaled residuals:

Min	1Q	Median	3Q	Max
-3.14574	-0.59704	0.04685	0.61263	2.30812

Random effects:

Groups	Name	Variance	Std.Dev.
Blok	(Intercept)	0.02135	0.1461
	Residual	0.17997	0.4242

Number of obs: 186, groups: Blok, 21

Fixed effects:

	Estimate	Std. Error	df	t value	Pr(> t)
(Intercept)	1.9502	0.1436	165.5642	13.584	< 2e-16 ***
typePinus plantation	0.6566	0.1533	176.8780	4.283	3.02e-05 ***
typePinus plantation - Ps	0.9551	0.1755	173.7198	5.442	1.77e-07 ***
typePinus poor	0.3610	0.2064	163.7470	1.749	0.082189 .
typePinus poor - Ps	0.7134	0.1741	165.6991	4.097	6.54e-05 ***
typeQ. petraea	0.6022	0.1689	174.3143	3.566	0.000467 ***
typeQ. rubra	0.2504	0.1873	174.1426	1.337	0.183022
typeQuercus-Acer-Tilia	0.6165	0.1714	170.3561	3.598	0.000421 ***
typeRobinia	0.8096	0.1982	176.9397	4.085	6.67e-05 ***

anova(mo.shan)

Type III Analysis of Variance Table with
Satterthwaite's method

	Sum Sq	Mean Sq	NumDF	DenDF	F value	Pr(>F)
type	8.2356	1.0294	8	155.77	5.7201	2.202e-06 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1						

cld(emmeans(mo.shan, ~type,type='resp'))

type	emmean	SE	df	lower.CL	upper.CL	group
Fagus	1.95	0.145	165.4	1.66	2.24	1
Q. rubra	2.20	0.130	169.7	1.94	2.46	12
Pinus poor	2.31	0.153	131.1	2.01	2.61	12
Q. petraea	2.55	0.106	61.3	2.34	2.76	23
Quercus-Acer-Tilia	2.57	0.105	74.1	2.36	2.78	23
Pinus plantation	2.61	0.072	57.2	2.46	2.75	23
Pinus poor - Ps	2.66	0.105	90.7	2.46	2.87	23
Robinia	2.76	0.144	163.2	2.47	3.05	23
Pinus plantation - Ps	2.91	0.107	123.5	2.69	3.12	3





Table 4 Analysis of variance for alpha diversity indices among forest types studied, assessed using linear mixed-effects models (with study plot block as a random intercept)

Response	Variable	df	Sum of Squares	Mean Square	F	Pr(> F)	Block random effects SD
Species richness	Forest type	8	160.3678	20.0460	20.046	< 0.0001	0.265
Shannon diversity index	Forest type	8	8.2356	1.0294	5.720	< 0.0001	0.146
Faith's phylogenetic diversity	Forest type	8	17,473,654.8014	2,184,206.8502	10.821	< 0.0001	286.098
Mean pairwise distance	Forest type	8	184,069.1143	23,008.6393	3.327	0.0014	62.986
Functional dispersion	Forest type	8	0.0086	0.0011	1.978	0.0525	0.008
Functional richness	Forest type	8	0.0003	0.0000	6.703	< 0.0001	0.002

Shannon's diversity index



Przykład – co decyduje o cechach roślin?


Table 1. Comparison of Linear Mixed Models for the Parameters Studied

Response	Fixed effects	AIC	R_m^2	R_c^2
SLA	Intercept only	61,395.630	0.000	0.53
	Species	57,457.420	0.526	0.75
	Habitat	61,360.600	0.027	0.53
	Species $\times$ habitat	56,054.150	0.577	0.81
LMF	Intercept only	– 1679.004	0.000	0.45
	Species	– 5438.193	0.499	0.84
	Habitat	– 1675.422	0.027	0.45
	Species $\times$ habitat	– 6299.425	0.544	0.85
TLA	Intercept only	52,286.910	0.000	0.52
	Species	50,374.540	0.261	0.64
	Habitat	52,267.520	0.009	0.53
	Species $\times$ habitat	49,219.380	0.359	0.74
Aboveground biomass	Intercept only	5102.774	0.000	0.54
	Species	3600.211	0.271	0.75
	Habitat	5102.840	0.024	0.54
	Species $\times$ habitat	3023.296	0.371	0.75

Intercept only is a null model; in all models collection site was a random effect.

Ecossystems (2020) 23: 555–569
<https://doi.org/10.1007/s10021-019-00421-6>

ECOSYSTEMS
 © 2019 The Author(s)



Leaf Traits and Aboveground Biomass Variability of Forest Understory Herbaceous Plant Species

Sonia Paż-Dyderska,^{1,2} Marcin K. Dyderski,² Piotr Szwaczka,¹
 Marta Brzezicha,¹ Karolina Bigos,¹ and Andrzej M. Jagodziński^{1,2*}

LMM w układzie hierarchicznym

4 obiekty, po 50 poletek w każdym

`lmer(biomasa ~ land.use.history + invasion + (1 | variant:plot), dane)`

plot zagnieżdżony w variant - czyli efekty losowe na poziomie plot i variant

zakładamy że dla każdego mamy random intercept

SD tych modyfikacji interceptów wynosi 0,0837

R2c i R2m - z `r.squaredGLMM()`



Contents lists available at ScienceDirect

Forest Ecology and Management

journal homepage: www.elsevier.com/locate/foreco



Effects of land use change and *Quercus rubra* introduction on *Vaccinium myrtillus* performance in *Pinus sylvestris* forests

Beata Wozniwoda^{a,*}, Marcin K. Dyderski^b, Andrzej M. Jagodziński^b

^a Department of Geobotany and Plant Ecology, Faculty of Biology and Environmental Protection, University of Łódź, Banacha 12/16, PL-90-237 Łódź, Poland

^b Institute of Dendrology, Polish Academy of Sciences, Parkowa 5, PL-62-035 Kórnik, Poland



Table 2

Differences in dry biomass and biomass allocation of *V. myrtillus* shoots (ramets) between types of pine forest assessed using linear mixed effect models.

Dry shoot mass (n = 400)	Random effects	Variance	SD	Mixed model parameters	–
–	Plots nested in variant	0.0070	0.0837	R_m^2	0.1159
–	Residuals	0.1557	0.3946	R_c^2	0.1540
–	Fixed effects	Estimate	SE	t	Pr(> t)
–	(Intercept)	0.745	0.041	18.110	< 0.001
–	Land use history – recent forest	–0.243	0.048	–5.110	< 0.001
–	Invasion – <i>Q. rubra</i>	–0.162	0.048	–3.401	0.002

random slope

Gdy nachylenie zależy od gatunku




Fig. 2. SLA differences between sunny and shaded parts of the crown.

Table 1

Parameters of the model explaining SLA variability.

Fixed effects	Estimate	SE	t	Pr(≥ t)
Intercept	161.27	9.725	16.58	< 0.0001
Light variant (shade)	69.851	6.276	11.13	< 0.0001
Random effect	Variable	SD	Model performance	
Species:Family	Intercept	38.28	R_m^2	0.1216
Species:Family	Light variant (shade)	23.55	R_c^2	0.8302
Family	Intercept	51.36	AIC	6307.526
Family	Light variant (shade)	28.26	AIC ₀	7041.933
Residual		41.31		

Forest Ecology and Management 472 (2020) 118254



Contents lists available at ScienceDirect

Forest Ecology and Management

journal homepage: www.elsevier.com/locate/foreco

On the sunny side of the crown – quantification of intra-canopy SLA variation among 179 taxa

Sonia Paż-Dyderska^{a,*}, Marcin K. Dyderski^a, Kinga Nowak^a, Andrzej M. Jagodziński^{a,b}

^a Institute of Dendrology, Polish Academy of Sciences, Parkowa 5, 62-035 Kórnik, Poland

^b Poznań University of Life Sciences, Faculty of Forestry, Department of Game Management and Forest Protection, Wojska Polskiego 71c, 60-625 Poznań, Poland

więcej o modelach mieszanych

<https://cran.r-project.org/web/packages/lme4/vignettes/lmer.pdf>

<https://www.r-bloggers.com/linear-mixed-models-in-r/>

<https://www.r-bloggers.com/getting-started-with-mixed-effect-models-in-r/>

<http://www.biecek.pl/WZUR/PrzemekBiecek2009.pdf>

<https://libra.ibuk.pl/book/39524> - podręcznik P. Biecka

Podsumowanie

obrazki, obrazki, obrazki!

-pomogą dobrać narzędzie i typ rozkładu

biologiczne znaczenie (effect size) > rozkład błędów > AIC > R^2 > p-value

effect size - o ile rośnie nam Y na jednostkę X?

p-value – pomocniczo

nie $p < 0.05$, tylko dokładna wartość – podawać całe summary!

nie można za dużo predyktorów na raz - dwóch strażników - VIF i AIC

Schemat pracy z modelami

- Czy może być model liniowy? Założenia (jutro)
- Model globalny – wszystkie zmienne które mają **sens biologiczny** (hipotezy)
- Sprawdzamy VIFy – czy nie są współliniowe *car::vif()*
- Selekcja modeli w oparciu o AIC/AICc *stats::step()* lub *MuMIn::dredge()*
- Model finalny:
 - *summary()* lub *anova()* do tabeli (pamiętaj o efektach losowych)
 - przy modelach mieszanych R^2_m i R^2_c
 - ocena effect size (wykresy) *ggeffects::ggpredict()*
- Czy nas to satysfakcjonuje? Czy ma biologiczny sens?




Figure 1. Correlation between Countries' Annual Per Capita Chocolate Consumption and the Number of Nobel Laureates per 10 Million Population.

<https://blogs.scientificamerican.com/the-curious-wavefunction/chocolate-consumption-and-nobel-prizes-a-bizarre-juxtaposition-if-there-ever-was-one/>



BIĄŁOWIESKA SZKOŁA STATYSTYKI

Jak zrobić ggpredicts na jednym ggplotcie ręcznie?


```
ggp1<-as.data.frame(ggpredict(mod11, 'V'))  
#stwórz ggpredict dla jednej zmiennej  
ggp1$group<-'V' #w kolumnie group wpisz nazwę zmiennej  
ggp2<-as.data.frame(ggpredict(mod11, 'N'))  
ggp2$group<-'N'  
ggp3<-as.data.frame(ggpredict(mod11, 'dens'))  
ggp3$group<-'dens'
```

```
ggp<-bind_rows(list(ggp1, ggp2, ggp3))  
#złącz listę tabel w jedno
```

Jak to wygląda?

```
head(ggp)
```

	x	predicted	std.error	conf.low	conf.high	group
1	0	5.748008	0.9440649	3.897675	7.598342	V
2	5	8.344449	0.8635288	6.651963	10.036934	V
3	10	10.940889	0.7880304	9.396378	12.485400	V
4	15	13.537330	0.7191579	12.127806	14.946853	V
5	20	16.133770	0.6589922	14.842169	17.425371	V
6	25	18.730210	0.6101146	17.534408	19.926013	V



```
ggplot(ggp, aes(x=x, y=predicted))  
+geom_ribbon(aes (ymin=predicted-  
std.error, ymax=predicted+std.error ),  
fill='gray80') +geom_line()  
+facet_wrap(~group, scales='free_x')
```

- widać effect size
- widać co wychodzi z modelu

Dodać rzeczywiste wartości ręcznie (czasem trzeba)

- trzeba zmeltować tabelkę z danymi


```
gg.points<-reshape2::melt(sosny[,c(2,6,9,10)], id.vars='AB')
```

```
> head(gg.points)
```

	AB	variable	value
1	2.4730	N	51.3192
2	0.2778	N	53.9168
3	0.1738	N	53.9161
4	1.8986	N	51.7522
5	1.8986	N	51.7523
6	6.2242	N	52.0138

```
colnames(gg.points)<-c('predicted','group','x')
```

```
#zmiana nazw kolumn na odpowiadające w tabeli ggp
```



```
ggplot(ggp, aes(x=x, y=predicted)) +geom_point(data=gg.points)
+geom_ribbon(aes(ymin=predicted-std.error ,ymax=predicted+std.error ),fill='gray80')
+geom_line()+facet_wrap(~group, scales='free_x')
```

#każdy geom_ może mieć swoją własną tabelę wejściową, definiowaną argumentem data=nazwa.tabeli